定量数据的统计描述

广州医科大学 公共卫生学院
阮红莲（**B2-513**）

- 例2-1 某地用随机抽样方法检查了140名成年男子红细胞计数，结果如表2-1所示。

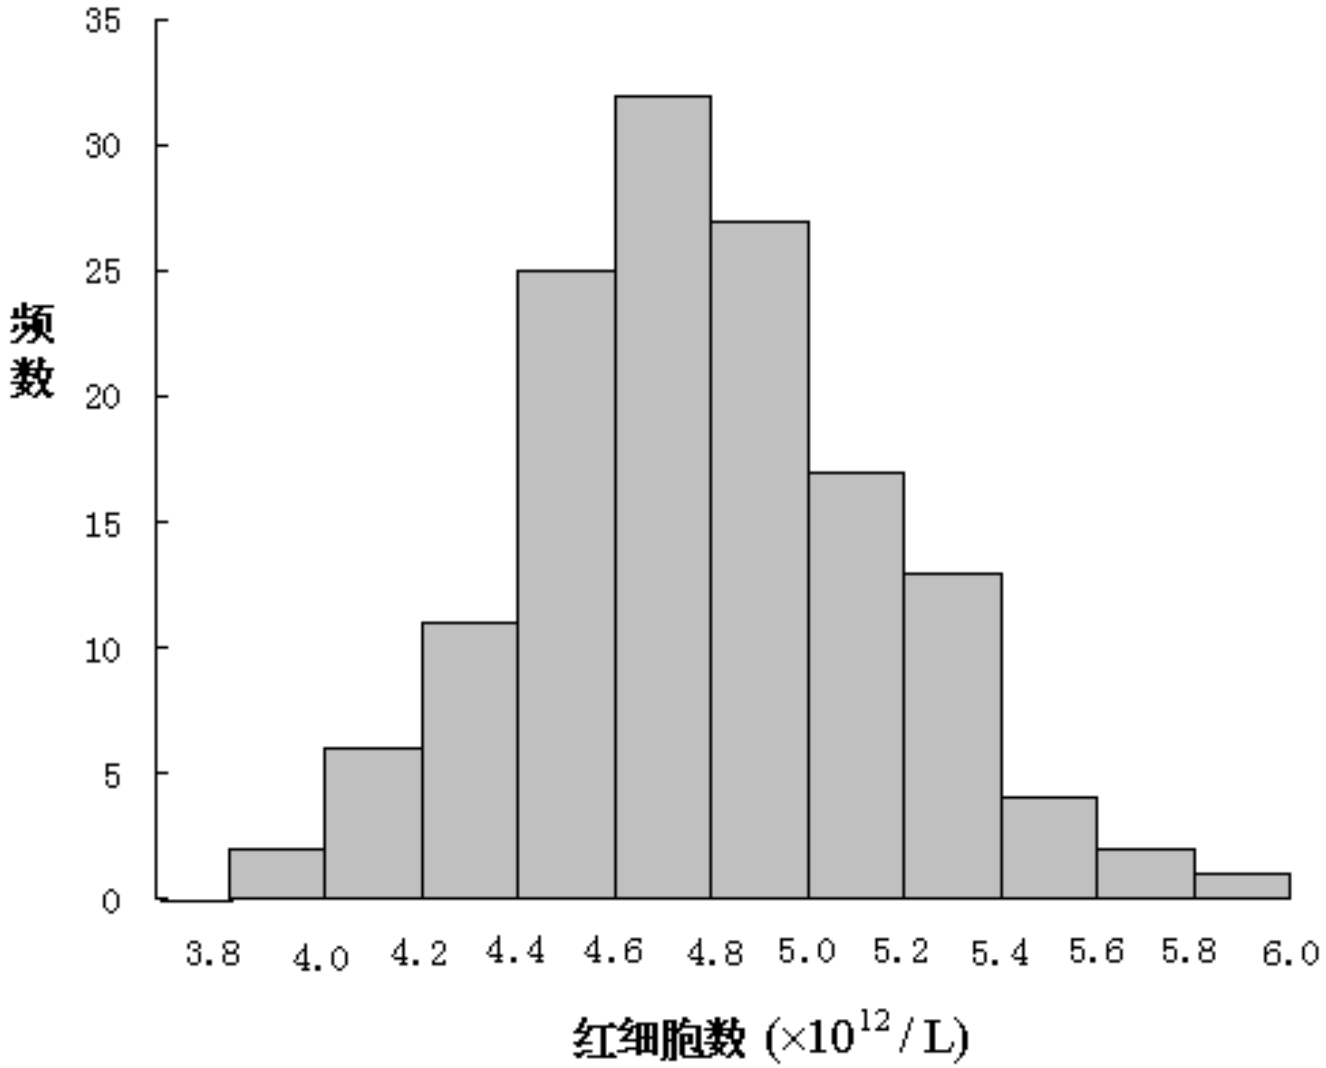
表2-1 某地140名成年男性红细胞数($\times 10^{12}$/L)

4.76	5.26	5.61	5.95	4.46	4.57	4.31	5.18
4.92	4.27	4.77	4.88	5.00	4.73	4.47	5.34
4.70	4.81	4.93	5.04	4.40	5.27	4.63	5.50
5.24	4.97	4.71	4.44	4.94	5.05	4.78	3.82
4.63	……	5.02	4.76				

讨论：如何有效地组织、整理和表达数据的信息?

表2-2　某地140名正常男子红细胞数的频数表

红细胞数	频　数	频　率(%)
3.80～	2	1.4
4.00～	6	4.3
4.20～	11	7.9
4.40～	25	17.9
4.60～	32	22.9
4.80～	27	19.3
5.00～	17	12.1
5.20～	13	9.3
5.40～	4	2.9
5.60～	2	1.4



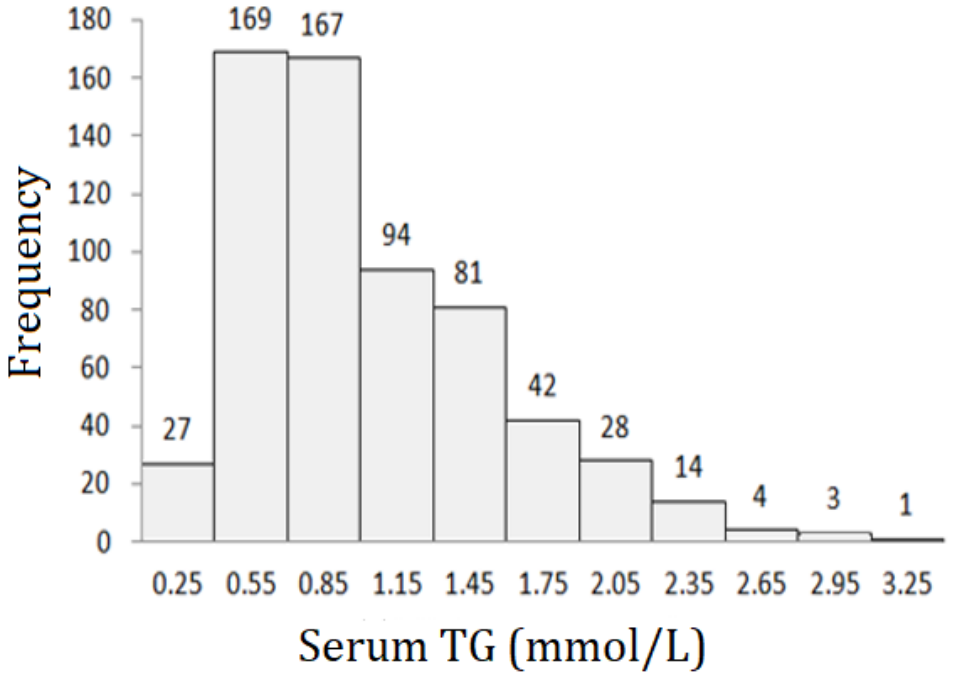


图1 630名正常女性血清甘油三酯含量(mmol/L) 的分布

表1 2007—2010年某院住院患者的年龄与总费用分析

年份	例数	年龄 $\bar{X} \pm S$	总费用（元） M（P25-P75）
2007	462	58.06±24.92	9564.37（4708.67-21324.93）
2008	499	53.06±28.08	9831.61（4641.24-21637.69）
2009	722	40.73±31.51	7742.91（3264.78-19834.59）
2010	748	41.01±31.25	8402.44（3801.40-22588.88）

Demographic Characteristics	Normal DBP (n= 125)	High DBP (n= 163)
Age (years)	42.8±15.2	43.3±16.7
BMI (kg/m^2)	22.2±4.3	21.6±3.0
DBP (mmHg)	58.5±6.9	92.2±11.6*
Sex [n (%)]		
Male	66 (52.8)	81 (49.7)
Female	59 (47.2)	82 (50.3)
Smoking history [n (%)]		
Never	79 (63.2)	102 (62.6)
Ex-smoker	2 (1.6)	5 (3.1)
Current smoker	44 (35.2)	56 (34.3)

主要内容



01 频数表与直方图

02 集中趋势的指标

03 离散趋势的指标

第一节　频数分布

- 由实验或观察等各种方式得到的原始定量数据，观察例数较多，可以对数据进行分组，然后制作频数表或绘制直方图，用以显示数据的分布规律。

一、频数表(frequency table)

- 频数（frequency）：变量值出现的次数，即例数；

- 频数表也称频数分布表，同时列出观察指标的可能取值区间及其在各区间内出现的频数。

表2-1 某地140名成年男性红细胞数($\times 10^{12}$/L)

4.76	5.26	5.61	5.95	4.46	4.57	4.31	5.18
4.92	4.27	4.77	4.88	5.00	4.73	4.47	5.34
4.70	4.81	4.93	5.04	4.40	5.27	4.63	5.50
5.24	4.97	4.71	4.44	4.94	5.05	4.78	3.82
4.63	……	5.02	4.76				

频数表的制作步骤：

1.确定组数	通常选择在8～15之间
2.确定组距	常用全距的1/10取整作为组距，等距
3.确定组限	每个组段的起点称组下限，终点称组上限。 第1组段包括最小值，最后1组包括最大值。 组段写为上限开口型，最末一组段同时写出其下限和上限。
4.确定频数	将原始数据采用划记法或计算机汇总，得到各个组段的观察例数（频数），列成频数表。

表2-2　某地140名正常男子红细胞数的频数表

红细胞数	频　数	频　率(%)	累计频数	累计频率(%)
3.80～	2	1.4	2	1.4
4.00～	6	4.3	8	5.7
4.20～	11	7.9	19	13.6
4.40～	25	17.9	44	31.5
4.60～	32	22.9	76	54.4
4.80～	27	19.3	103	73.7
5.00～	17	12.1	120	85.8
5.20～	13	9.3	133	95.1
5.40～	4	2.9	137	98.0
5.60～	2	1.4	139	99.4
5.80～ 6.00	1	0.7	140	100.0

从频数表可看出有两个重要的特征：

① 集中趋势（central tendency）：

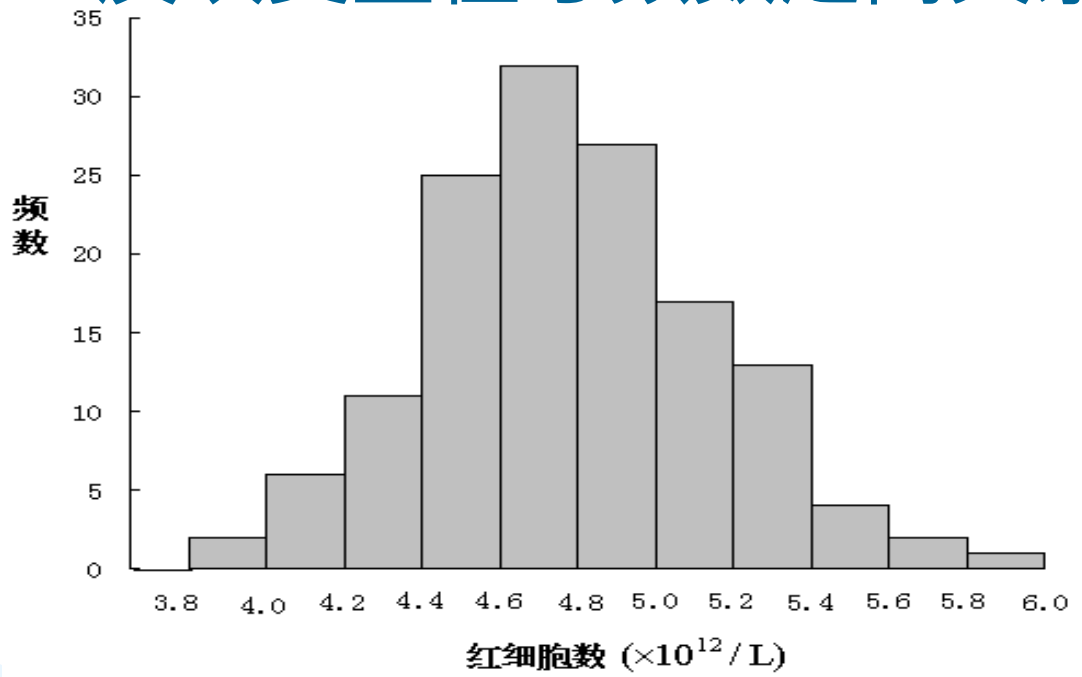
多数数据向中间集中

② 离散趋势(tendency of dispersion)：

少数数据向两端分散

二、直方图

反映变量值与频数之间关系的统计图



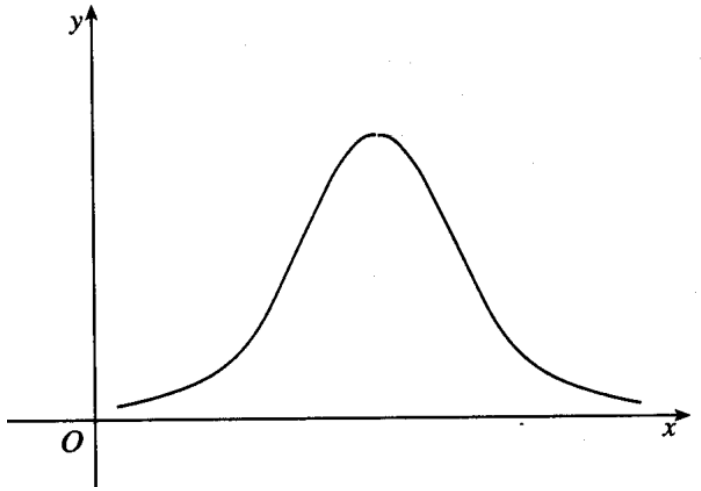


图**2-1　140**名正常男子红细胞计数的直方图

近似正态分布：中间高、两边低、左右对称

正偏分布（右偏）

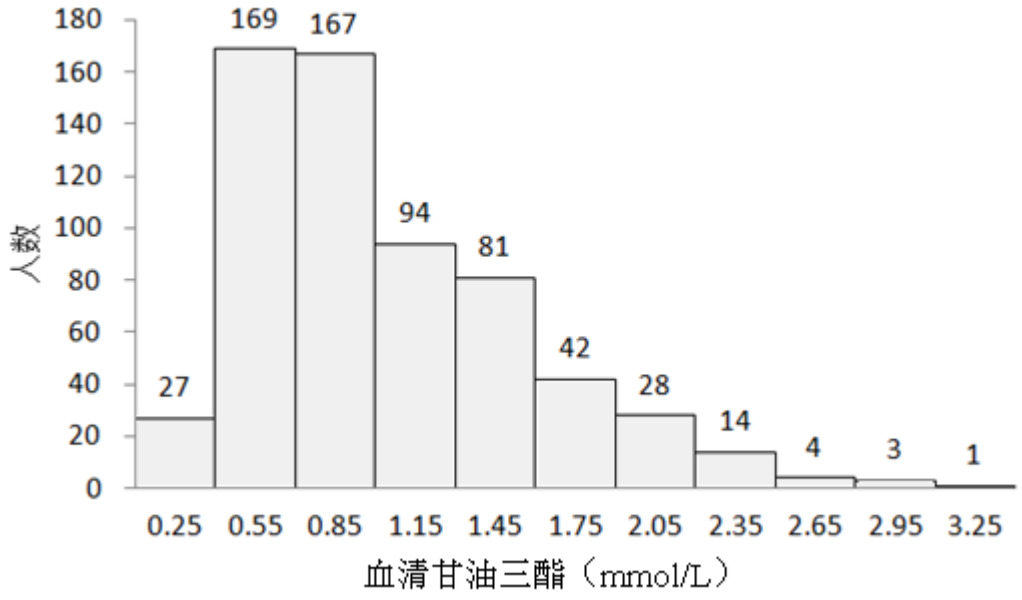


图2-2 630名正常女性血清甘油三酯含量(mmol/L) 的分布

负偏分布（左偏）

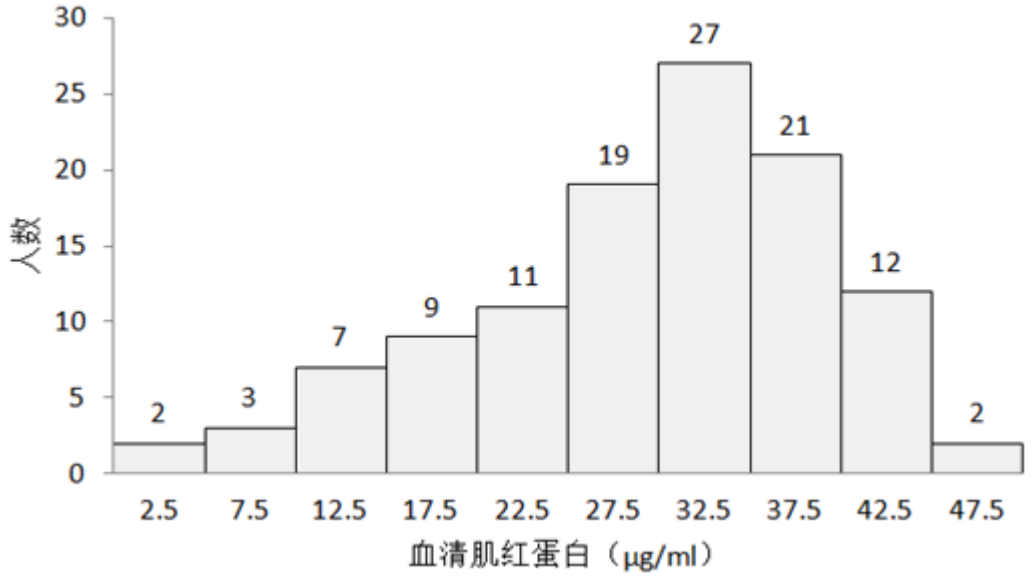
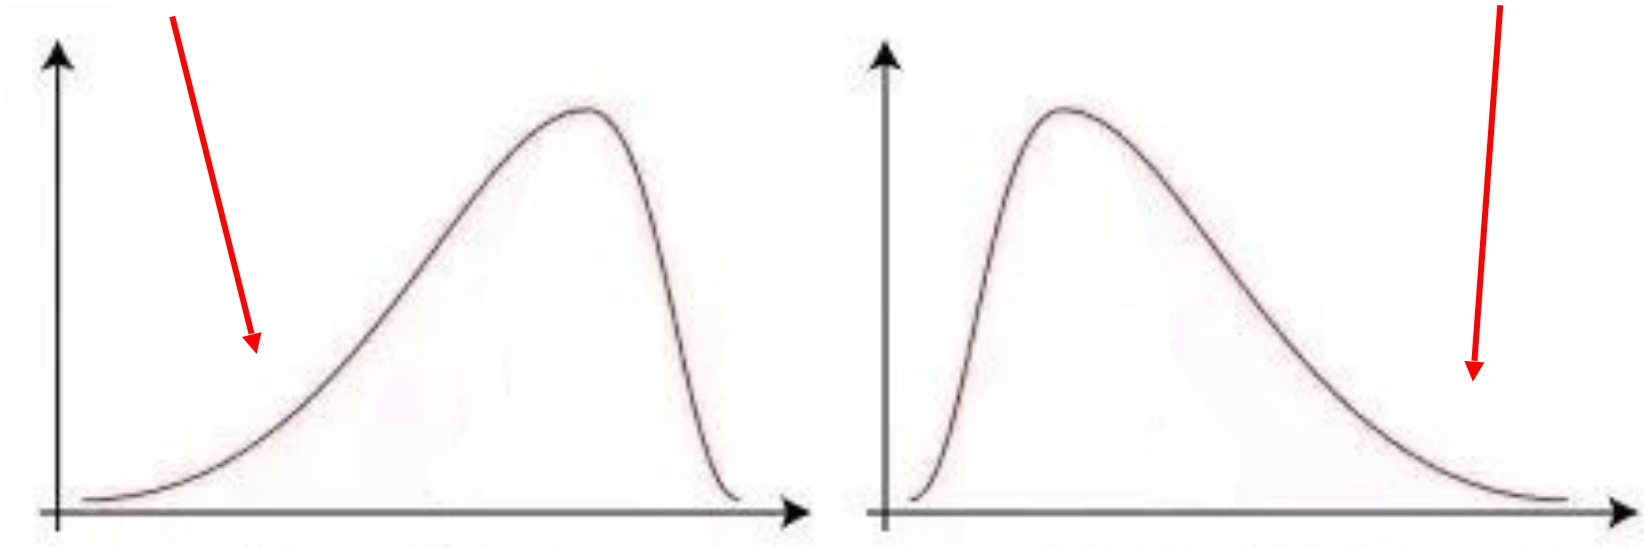


图2-3 100名女性血清肌红蛋白(μg/ml)的分布

怎样区分偏态分布:正偏/负偏

查看长尾的方向...



负偏/左偏

正偏/右偏

频数表与频数图比较

频数表不够直观，但读出数据精确

频数图比较直观，但读出数据不精确

如何对比评价多个组的定量数据

例1. 某次资格考试3名学生的考试成绩记录

	A	B	C
分数	88888	710869	86667

集中趋势

离散趋势

第二节 集中趋势的统计指标

平均数（average）：描述数值变量资料集中位置或平均水平的统计指标。

意义：常作为一组数据的代表值用于分析和进行组间差异的比较。

平均数种类：算术平均数（简称均数）、几何平均数、中位数，另有众数以及调和均数。

一、算术均数(arithmetic mean)

均数符号：总体均数为μ，样本均数为 $\bar{X}$

1．直接法计算算术均数：

$$\bar{x} = \frac{\sum x_i}{n} = \frac{x_1 + x_2 + \boxed{?} + x_n}{n}$$

例2-1：140名成年男性血红蛋白数的平均值

$$\bar{x} = \frac{(4.76 + 5.26 + 5.61 + \ldots + 5.02 + 4.76)}{140} = 4.776(\times 10^{12} / L)$$

2. 加权法

加权法（频数表法）基本思想：以组中值代表组内的变量值，简化计算

$$\bar{x} = \frac{\sum f_i x_i}{\sum f_i} = \frac{f_1 x_1 + f_2 x_2 + \boxed{?} + f_n x_n}{f_1 + f_2 + \boxed{?} + f_n} \quad (2\text{-}2)$$

表2-2　某地140名正常男子红细胞数的频数表

红细胞数	频数(f_i)	组中值（X）	$f_i X_i$
3.80～	2	3.90	7.80
4.00～	6	4.10	24.60
4.20～	11	4.30	47.30
4.40～	25	4.50	112.50
4.60～	32	4.70	150.40
4.80～	27	4.90	132.30
5.00～	17	5.10	86.70
5.20～	13	5.30	68.90
5.40～	4	5.50	22.00
5.60～	2	5.70	11.40
5.80～ 6.00	1	5.90	5.90
合计	140(Σf_i)	—	669.80($\Sigma f_i X_i$)

将表2-2中数据代入公式2-2，有

$$\bar{x} = \frac{2\times 3.90 + 6\times 4.10 + \boxed{?} + 1\times 5.90}{140} = 4.784(\times 10^{12}$$

算术均数的适应情形：
主要适用于对称分布或偏度不大的资料，
尤其适合正态分布资料。

二、几何均数(geometric mean)

定义：是将n个观察值x的乘积再开n次方，所得的平方根，记为G

适用情形：

（1）观察值呈倍数关系或近似倍数关系，如抗体效价及抗体滴度，某些传染病的潜伏期，细菌计数等；

（2）对数正态资料。

1. 直接法

$$G = \sqrt[n]{x_1 x_2 \boxed{?} x_n}$$

$$= \lg^{-1}\left(\frac{\lg x_1 + \lg x_2 + \boxed{?} + \lg x_n}{n}\right) = \lg^{-1}\left(\frac{\sum \lg x_i}{n}\right) \quad (2\text{-}4)$$

2. 加权法

$$G = \lg^{-1}\left(\frac{\sum f_i \lg x_i}{\sum f_i}\right)$$

$$= \lg^{-1}\left(\frac{f_1 \lg x_1 + f_2 \lg x_2 + \boxed{?} + f_n \lg x_n}{\sum f_i}\right) \quad (2\text{-}5)$$

例2.2　测得10个人的血清滴度的倒数分别为2，2，4，4，8，8，8，8，32，32，求平均滴度。

$$G = \lg^{-1}\left(\frac{\lg 2+\lg 2+\lg 4+\lg 4+\lg 8+\lg 8+\lg 8+\lg 8+\lg 32+\lg 32}{10}\right)\approx 7$$

注：计算几何均数的观察值不能为0或负数，因无法求对数先加上一常数即可，如$X'=K+X$，则X'可取对数。

最终的几何均数结果：$G=G'-K$

平均的意义上，每个小朋友拥有多少零花钱？

随机抽样获得10个小朋友的零花钱数据如下:



编号	1	2	3	4	5	6	7	8	9	10
零花钱（元）	1	1	1	1	1	1	1	1	1	101

算术均值： $(9\times1 + 1\times101)\div10 = 110\div10 = 11$ 元

思考：11元能否很好代表小朋友拥有的零花钱数量?

三、中位数与百分位数

中位数(median)：一组观察值按大小顺序排列，居中心位置的数值，记为M。

1．中位数的直接估计：

① ***n***为奇数时，正中位置的数值就是***M***；

$$M = X_{(n+1)/2}$$

1，2，6，10，19

② ***n***为偶数时，居中位置两个数值的平均数就是***M***。

$$M = [X_{n/2} + X_{n/2+1}]/2$$

2，4，8，10，15，20

2.频数表法计算中位数:

- 编制频数表
- 由小到大计算累计频数、累计频率
- 找出M或P_x所在组
- 代入公式计算

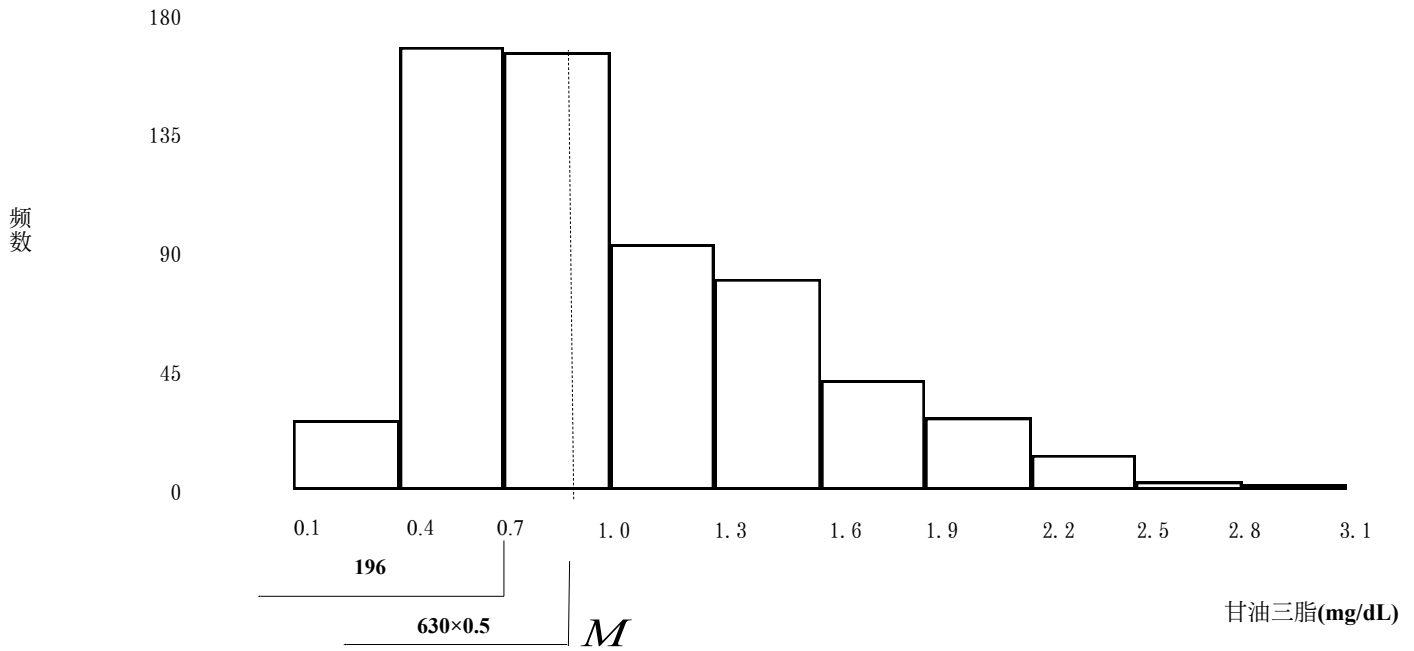
$$M = L + \left(\frac{0.5n - f_L}{f_M} \right) i_M$$

L、i_M、f_M分别为M所在组段的下限、组距和频数，f_L为M所在组段之前各组段的累积频数。

频数表资料

表2-4　某地630名正常女性血清甘油三脂含量(mg/dl)

甘油三脂	频数	累计频数	累计频率(%)	
0.10～	27	27	4.3	
0.40～	169	196	31.1	
0.70～	167	363	57.6	M
1.00～	94	457	72.5	
1.30～	81	538	85.4	
1.60～	42	580	92.1	
1.90～	28	608	96.5	
2.20～	14	622	98.7	
2.50～	4	626	99.4	
2.80～	3	629	99.8	
3.10～	1	630	100.0	
合计	630	-	-	

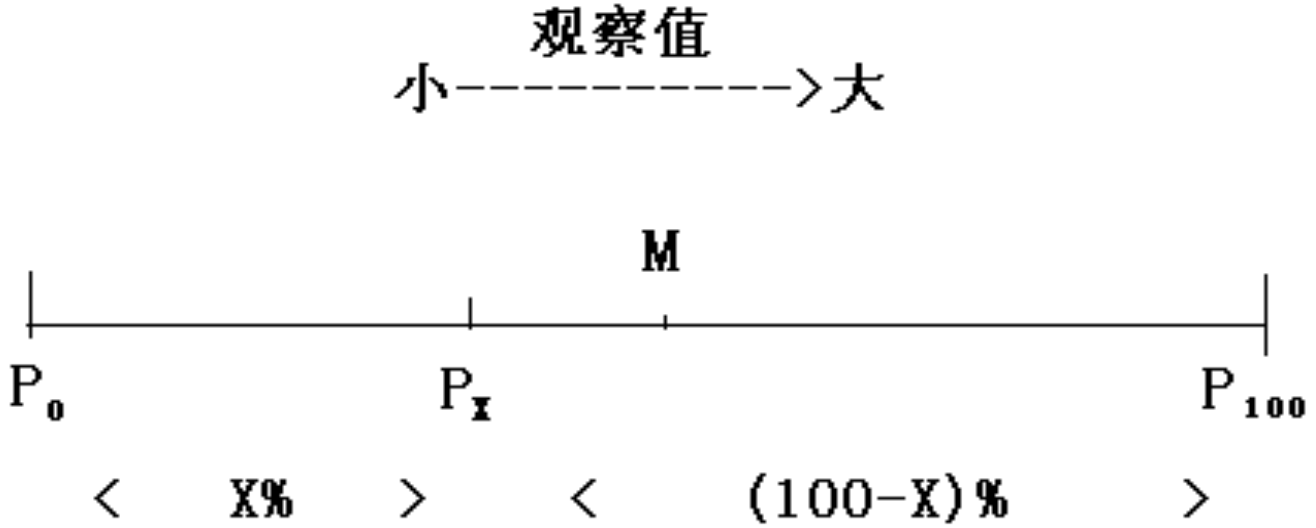


$$M = L + \left(\frac{0.5n - f_L}{f_M} \right) i_M$$

$$M = 0.70 + \frac{630 \times 0.5 - 196}{167} \times 0.30 = 0.914$$

百分位数（percentile）

- 把一组数据从小到大排列，分成100等份，分割界限上的值就是百分位数，记为Px
- Px将全部观测值分为两部分，理论上x%的变量值比它小，(100-x)%的变量值比它大。



怎样求解百分位数?

$$P_x = L + \left(\frac{n \cdot x\% - f_L}{f_x} \right) i_x$$

L: 组段的下限; i_x: 组距; f_x: 频数;

f_L: P_x所在组段之前的累积频数。

例2.5 计算例2.4的百分位数P_{25}、P_{75}、P_{90}。

$$P_{25} = 0.40 + \frac{630 \times 0.25 - 27}{169} \times 0.30 = 0.632(\text{mmol/L})$$

$$P_{75} = 1.30 + \frac{630 \times 0.75 - 457}{81} \times 0.30 = 1.357(\text{mmol/L})$$

$$P_{90} = 1.60 + \frac{630 \times 0.90 - 538}{42} \times 0.30 = 1.807(\text{mmol/L})$$

中位数与百分位数的应用：

1. 中位数常用于偏态分布（如发汞、尿铅）；一端或两端无确定数值；分布情况不明。
2. 百分位数可描述数据序列在某百分位置的水平。多个百分位数结合使用如P_{25}和P_{75}可以描述数据的分散程度，用$P_{2.5}$和$P_{97.5}$规定医学95%的参考值范围等。

常用平均数的意义及应用场合

平均数	意义	应用场合
均数	平均数量水平	应用甚广，最适用于对称分布，特别是正态分布
几何均数	平均增（减）倍数	等比资料；对数正态分布资料
中位数	位次居中的观察值水平	偏态分布；分布不明；分布末端无确定值

百分位数描述观察序列在某百分位置的水平，可用于确定医学参考值范围，适用于任何分布。

第三节 变异程度的统计指标

平均指标描述样本数据的集中趋势
(一般水平)

变异指标描述样本数据的离散趋势
(差别大小)

一、极差（range）

- 又称全距，用***R***表示，是最大值与最小值之差。

优点 — 简单明了，易于使用；

缺点： 只利用了2个数据的信息，因此不稳定。

应用 — 粗略说明变量波动范围时。

二、四分位数间距(quartile interval)

四分位数间距用Q表示，是上四分位数$Q_U(P_{75})$和下四分位数$Q_L(P_{25})$之差。

$$Q = P_{75} - P_{25}$$

优点 — 比全距稍稳健；

缺点 —多数数据的信息仍未利用；

应用 — 偏态分布资料。

三、方差与标准差

方差（**variance**）：离均差平方的均值

$$S^2 = \frac{\sum (X - \overline{X})^2}{n-1}$$

标准差（**standard deviation**）：方差的平方根，其实质是离均差的均值，反映平均差别大小。

$$S = \sqrt{\frac{\Sigma (X - \overline{X})^2}{n-1}}$$

方差和标准差的意义：都反映资料的变异程度大小

方差与标准差的计算实例

某项研究收集到的数据如下：

1, 2, 3, 4，5，试计算其方差与标准差。

四、变异系数（coefficient of variation，CV）

$$CV = \frac{S}{\bar{x}} \times 100\%$$

应用情形：

（1）变量的度量单位不同；

（2）变量的度量单位相同，但是均数的数量级相差悬殊。

变异系数的实例计算

- 某地20岁男子160人，身高均数为166.06cm，标准差为4.95cm; 体重均数为53.72kg,标准差为4.96kg。试比较身高与体重的变异程度。

身高 $$CV = \frac{4.95}{166.06} \times 100\% = 2.98\%$$

体重 $$CV = \frac{4.96}{53.72} \times 100\% = 9.23\%$$

小　结

1. 频数表与直方图
2. 反映定量数据平均水平的指标：

   算术均数、几何均数、中位数
3. 反映定量数据变异度的指标：

   全距、四分位数间距、方差/标准差、变异系数

定量数据的统计描述

- 图形的方法：直方图、箱式图
- 表格的方法：频数分布表
- 指标的方法：均值±标准差 / M（P25-P75）

资料分布	平均水平（集中趋势）	变异程度（离中趋势）
对称（正态分布）资料	算术均数	方差、标准差
非对称分布、分布类型未知或末端无确切数值	中位数	四分位数间距

The end ！
Thank you！