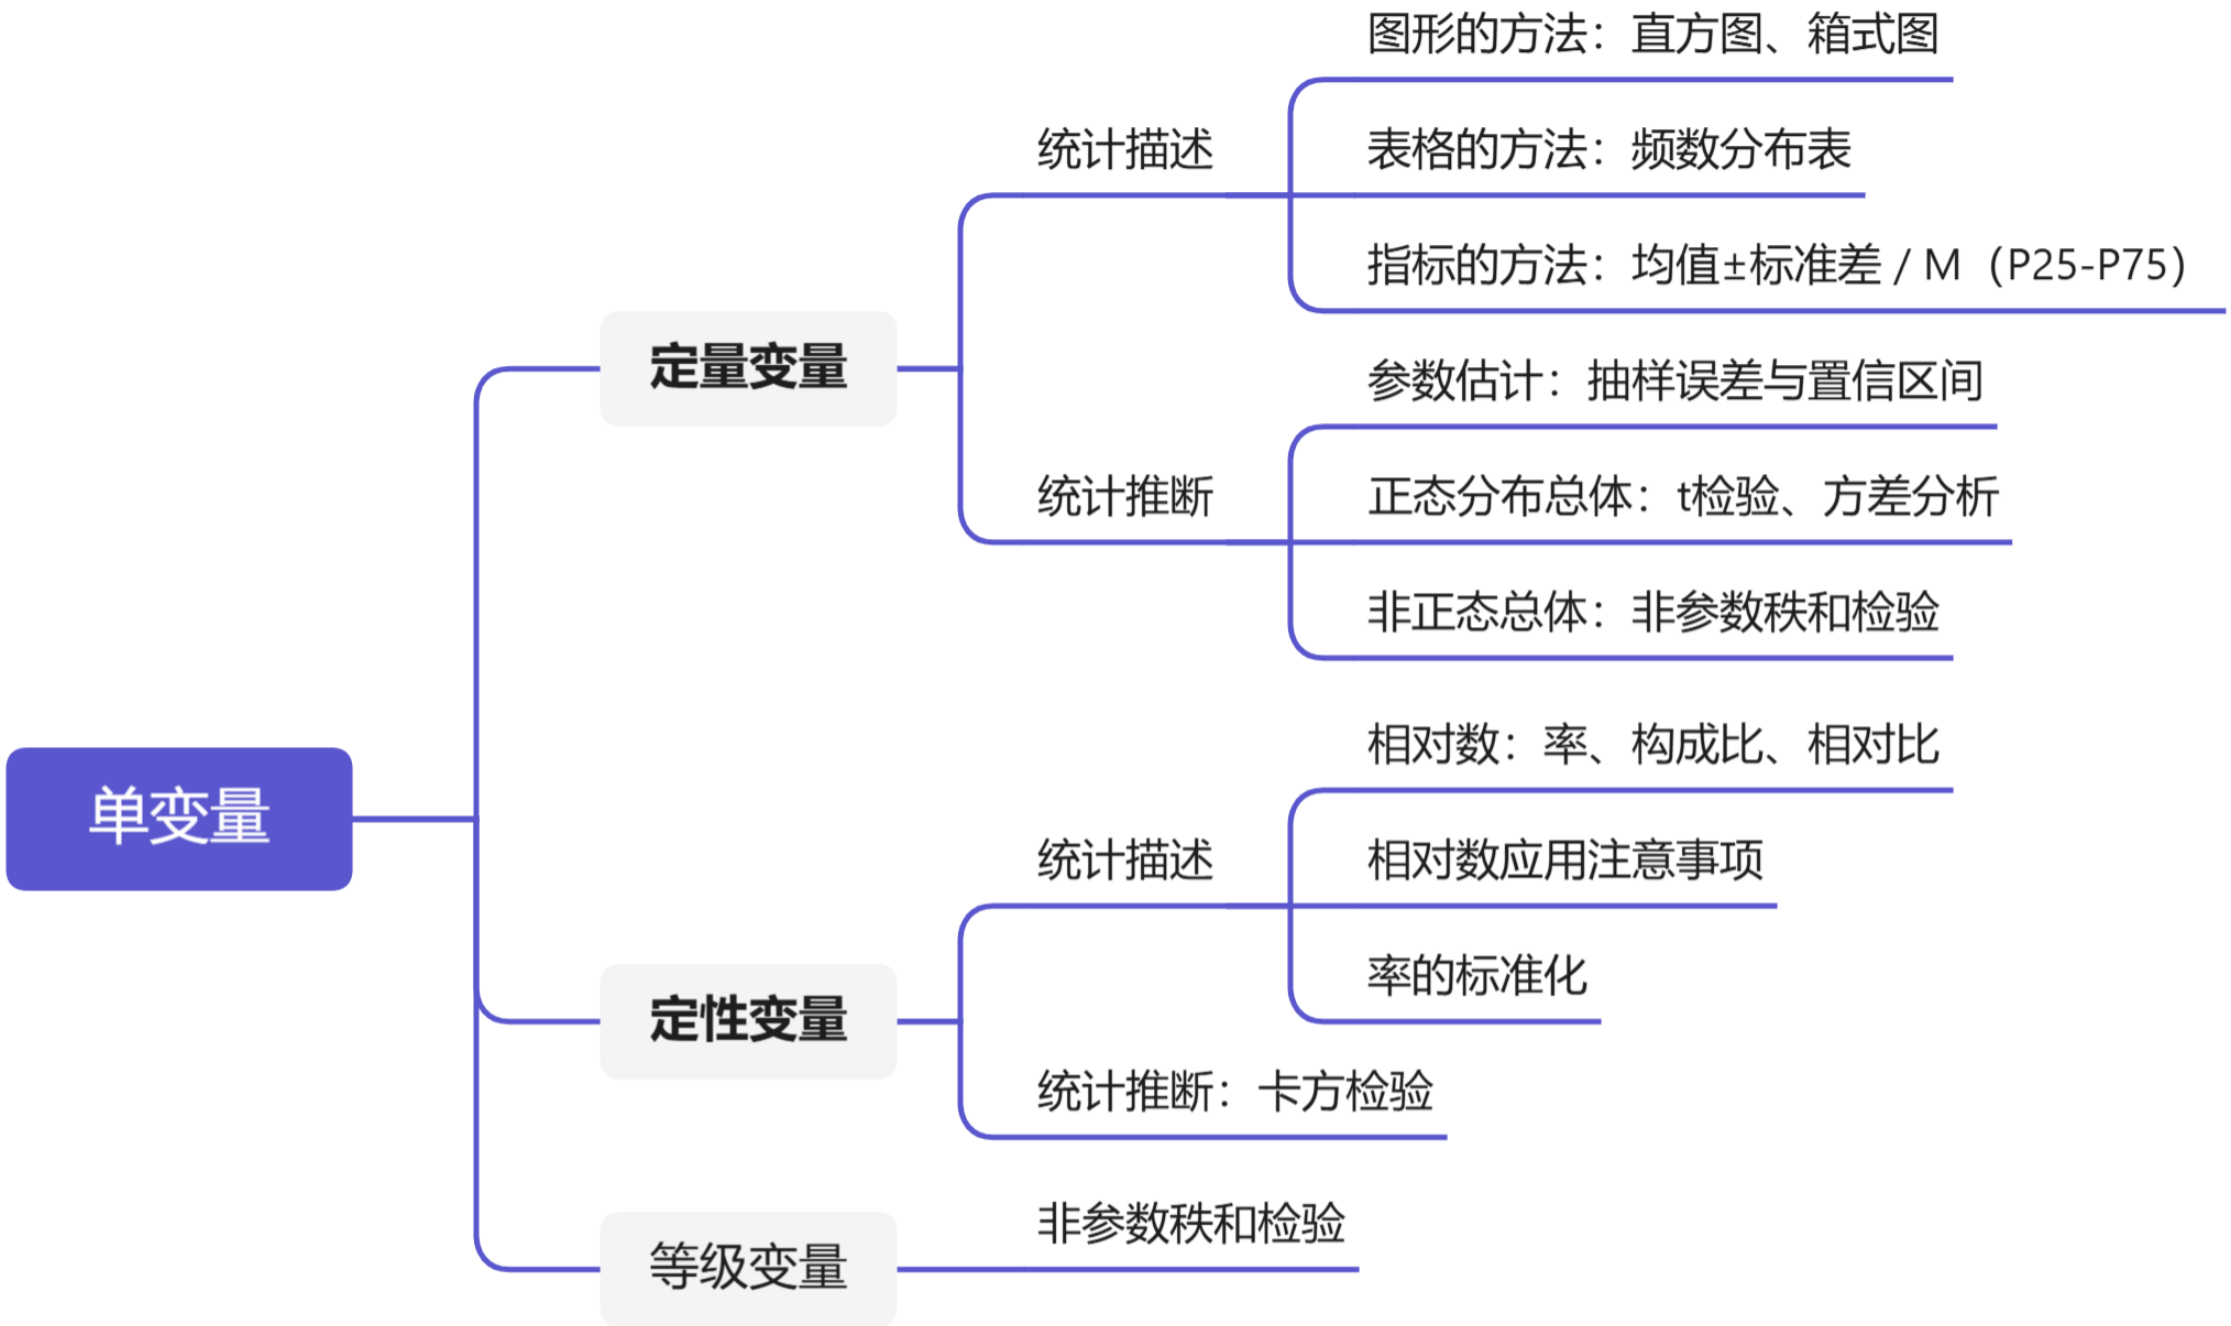
线性相关与回归

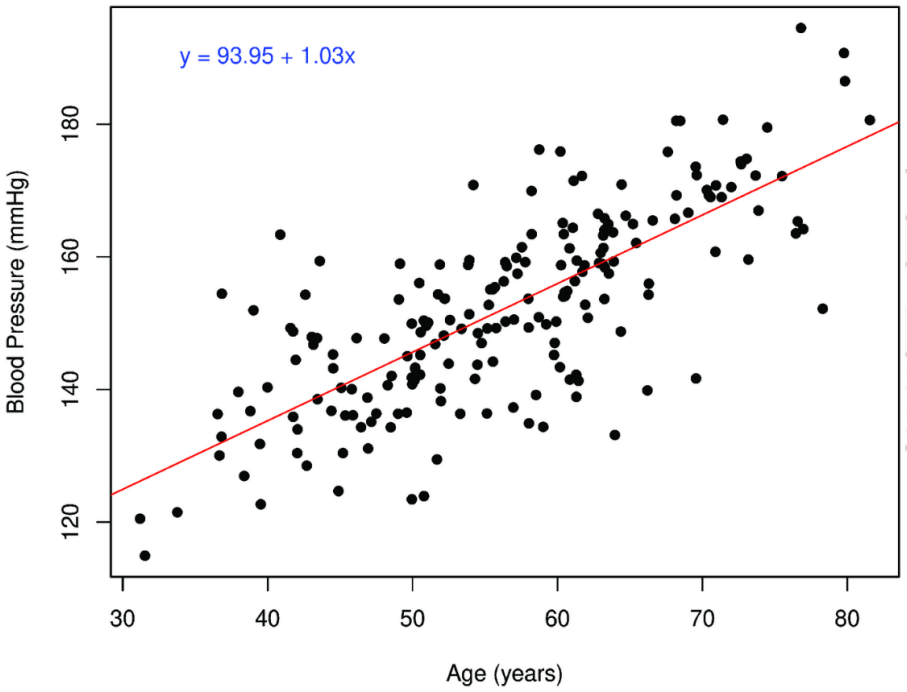
阮红莲

广州医科大学 公共卫生学院


单变量
定量变量
统计描述
图形的方法：直方图、箱式图
表格的方法：频数分布表
指标的方法：均值±标准差 / M（P25-P75）
统计推断
参数估计：抽样误差与置信区间
正态分布总体：t检验、方差分析
非正态总体：非参数秩和检验
定性变量
统计描述
相对数：率、构成比、相对比
相对数应用注意事项
率的标准化
统计推断：卡方检验
等级变量
非参数秩和检验

- 前面讨论了单个随机变量的统计分析方法，着重于比较**单个随机变量**的组间差别；
- 在医学研究中常常还需要分析**两个随机变量之间的关系**；例如：**研究年龄与血压的关系？年龄与肾小球滤过率的关系？能否用血清肌酐的含量估算肾小球滤过率（GFR）的高低?**
- **相关与回归**是研究两个或多个随机变量之间相互关系的重要的统计分析方法。

年龄与收缩压的线性回归分析

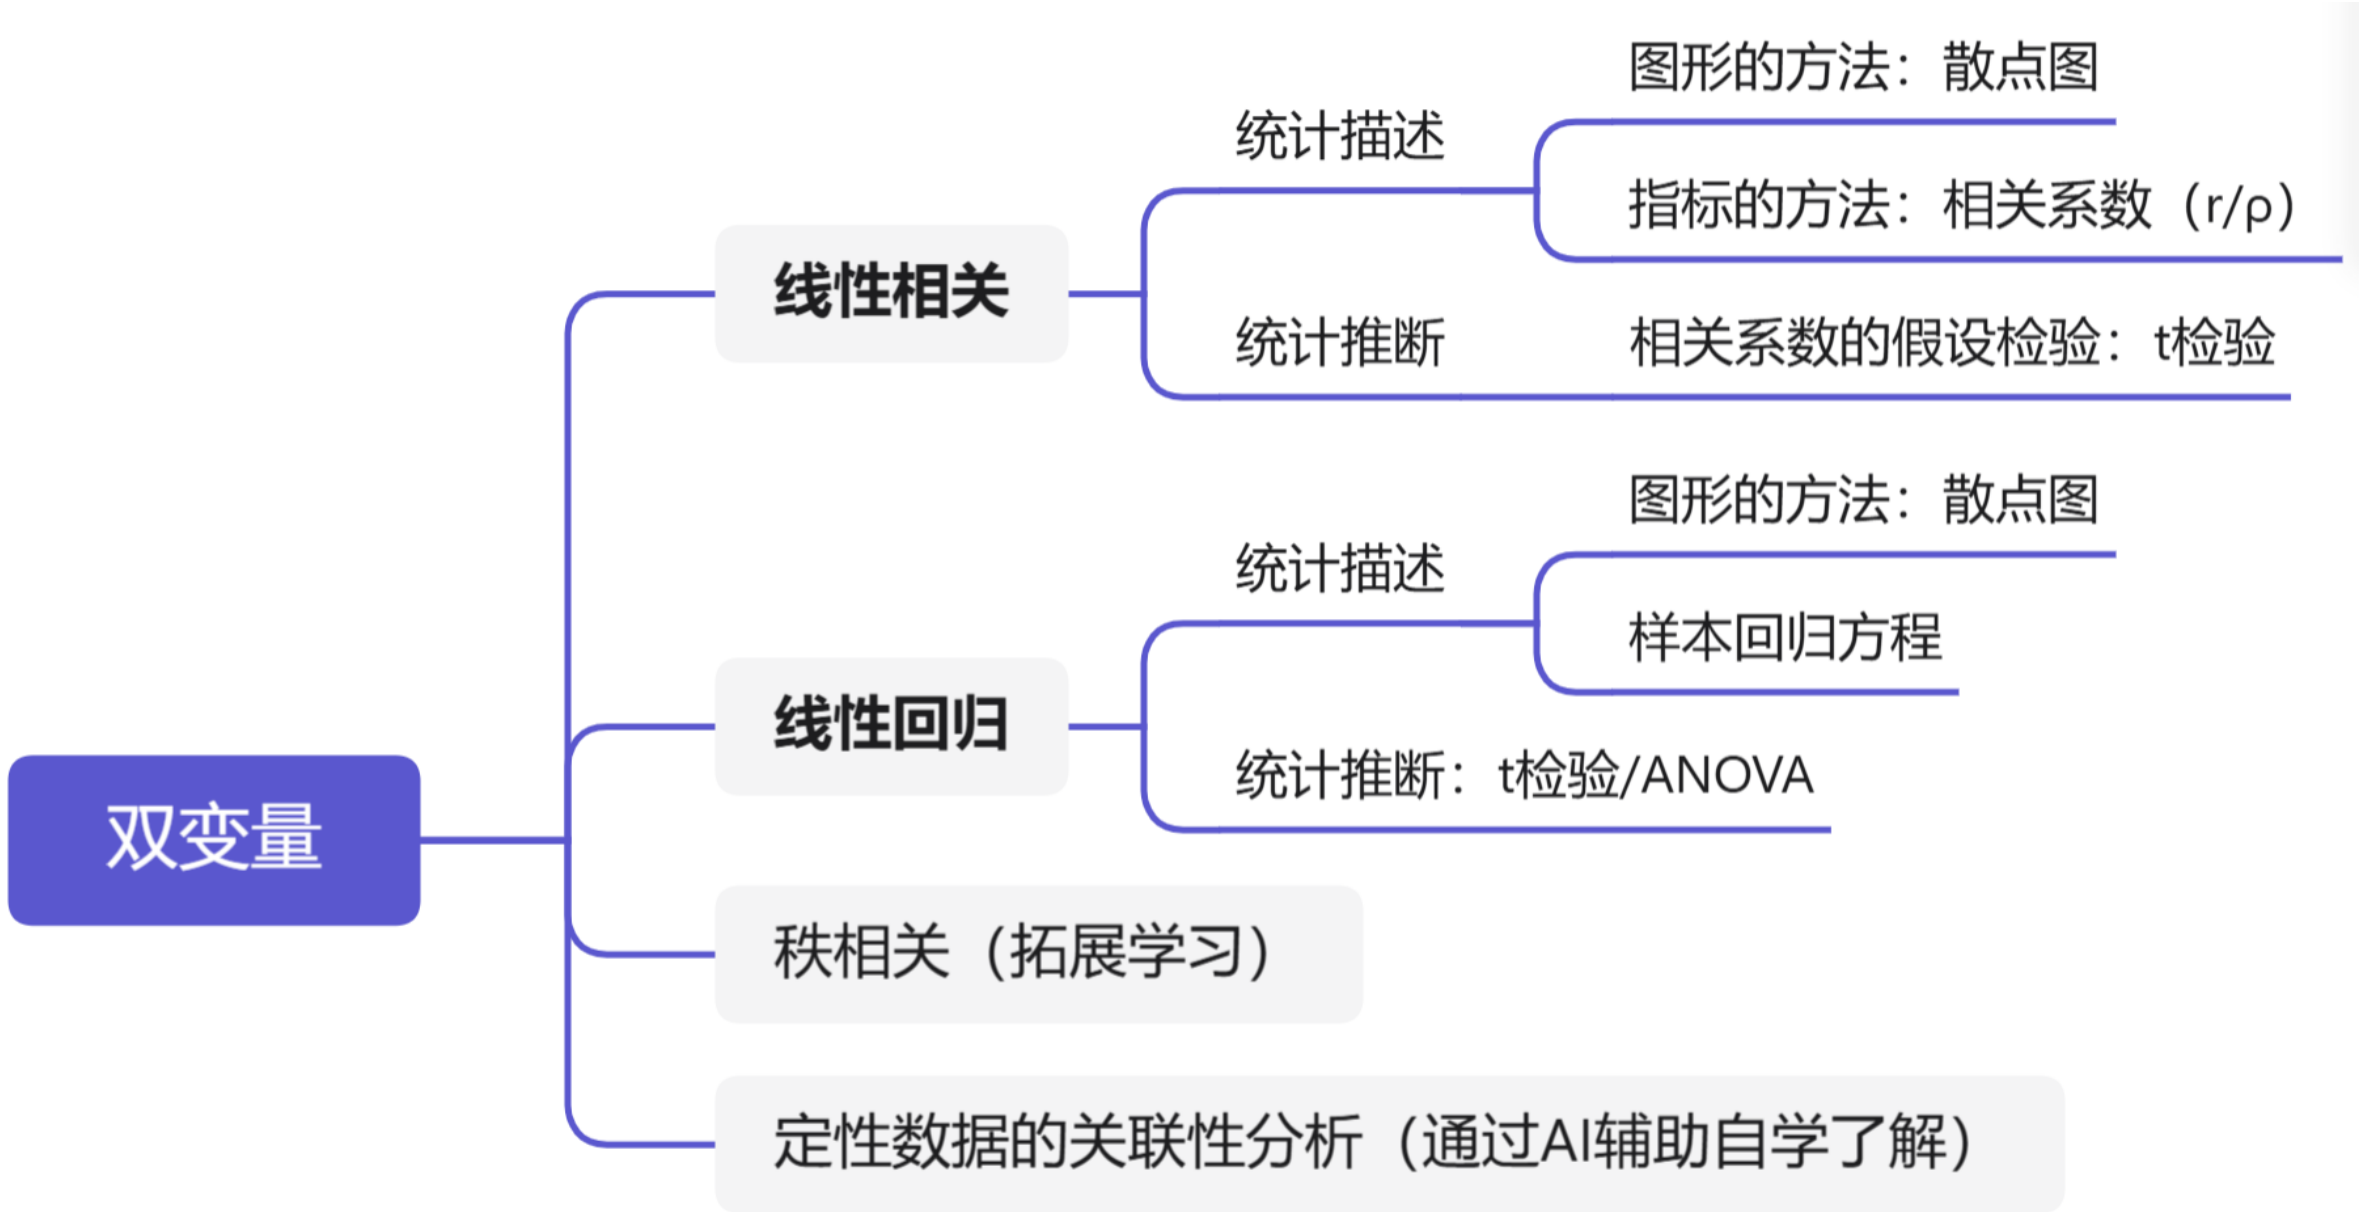


				95% CI		
Terms	**B**	**SE**	**t**	**Lower**	**Upper**	**p-value**
(Intercept)	93.95	3.67	25.62	86.72	101.18	<0.001
age	1.03	0.06	16.20	0.91	1.16	<0.001

B = Unstandardised coefficient; SE = Standard Error; CI = Confidence Interval

R^2 = 0.57; Residual standard error = 9.60; Residual df = 198; No. Obs. = 200

Blood pressure was found to be associated with age ($F(1, 198) = 262.3$, $p < 0.001$), with blood pressure increasing by 1.03 mmHg (95% CI: 0.91, 1.16) per year or 10.3 mmHg as age increases by 10 years (Table 2). Age explained approximately 57% ($R^2 = 0.57$) of the variance in blood pressure. Even small increases in blood pressure can have a significant impact on cardiovascular health, as sustained elevations contribute to an increased risk of adverse outcomes such as heart attack and stroke. For example, in middle age, a 2 mmHg increase in systolic blood pressure is associated with a 10% higher risk of ischemic heart disease and a 7% higher risk of stroke [34].


双变量
线性相关
统计描述
图形的方法：散点图
指标的方法：相关系数（r/ρ）
统计推断
相关系数的假设检验：t检验
线性回归
统计描述
图形的方法：散点图
样本回归方程
统计推断：t检验/ANOVA
秩相关（拓展学习）
定性数据的关联性分析（通过AI辅助自学了解）

主要内容

1 第一节 线性相关

2 第二节 线性回归

3 第三节 线性回归与相关应用的注意事项

例1 从男青年总体中随机抽取11名男青年组成样本，分别测量每个男青年的身高和前臂长，身高和前臂长均以cm为单位，测量结果如下表所示，试分析身高与前臂长之间的相关关系。

编号	身高（cm） (*X*)	前臂长（cm） (*Y*)
1	170	47
2	173	42
3	160	44
4	155	41
5	173	47
6	188	50
7	178	47
8	183	46
9	180	49
10	165	43
11	166	44

一、线性相关的概念

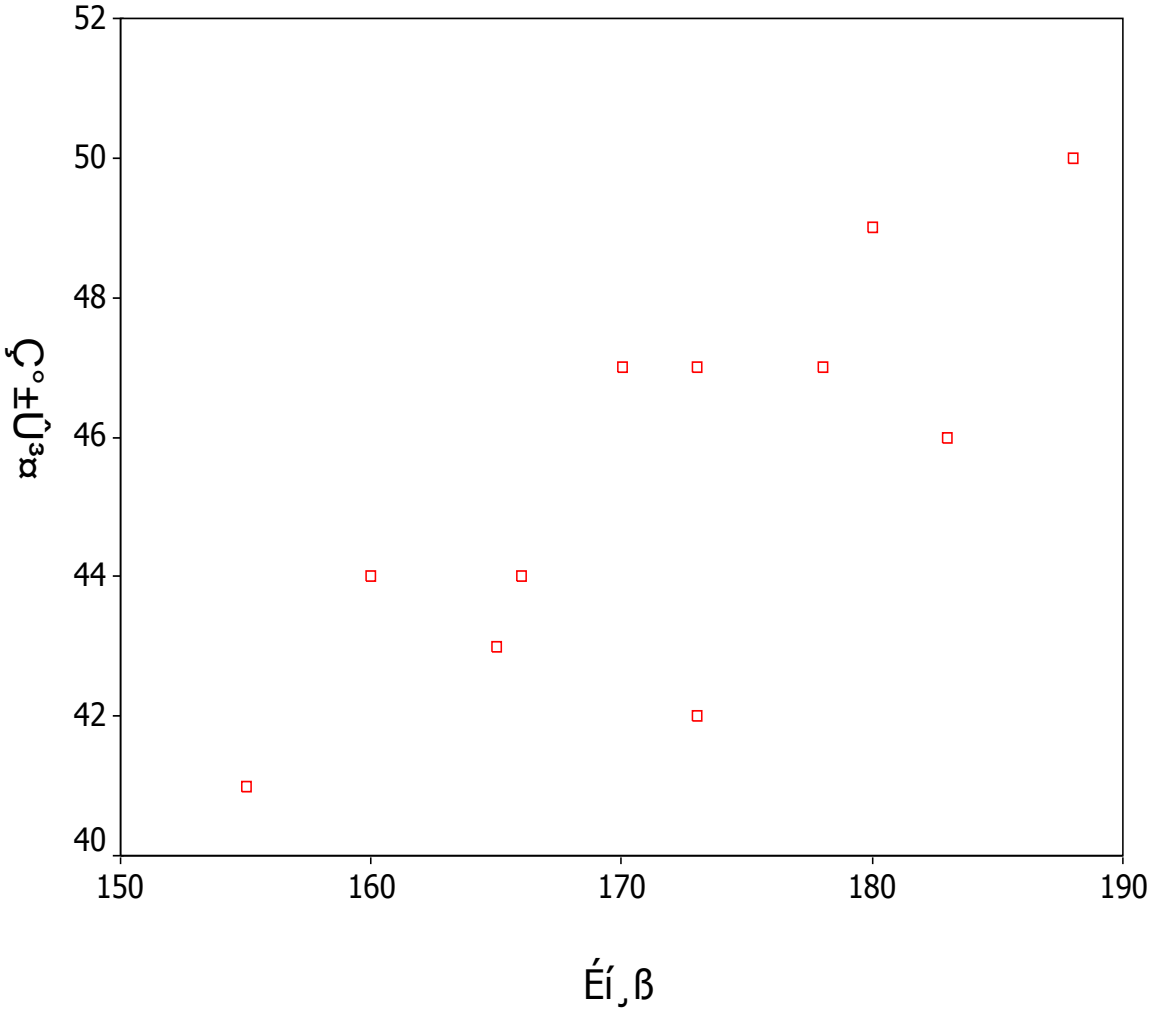
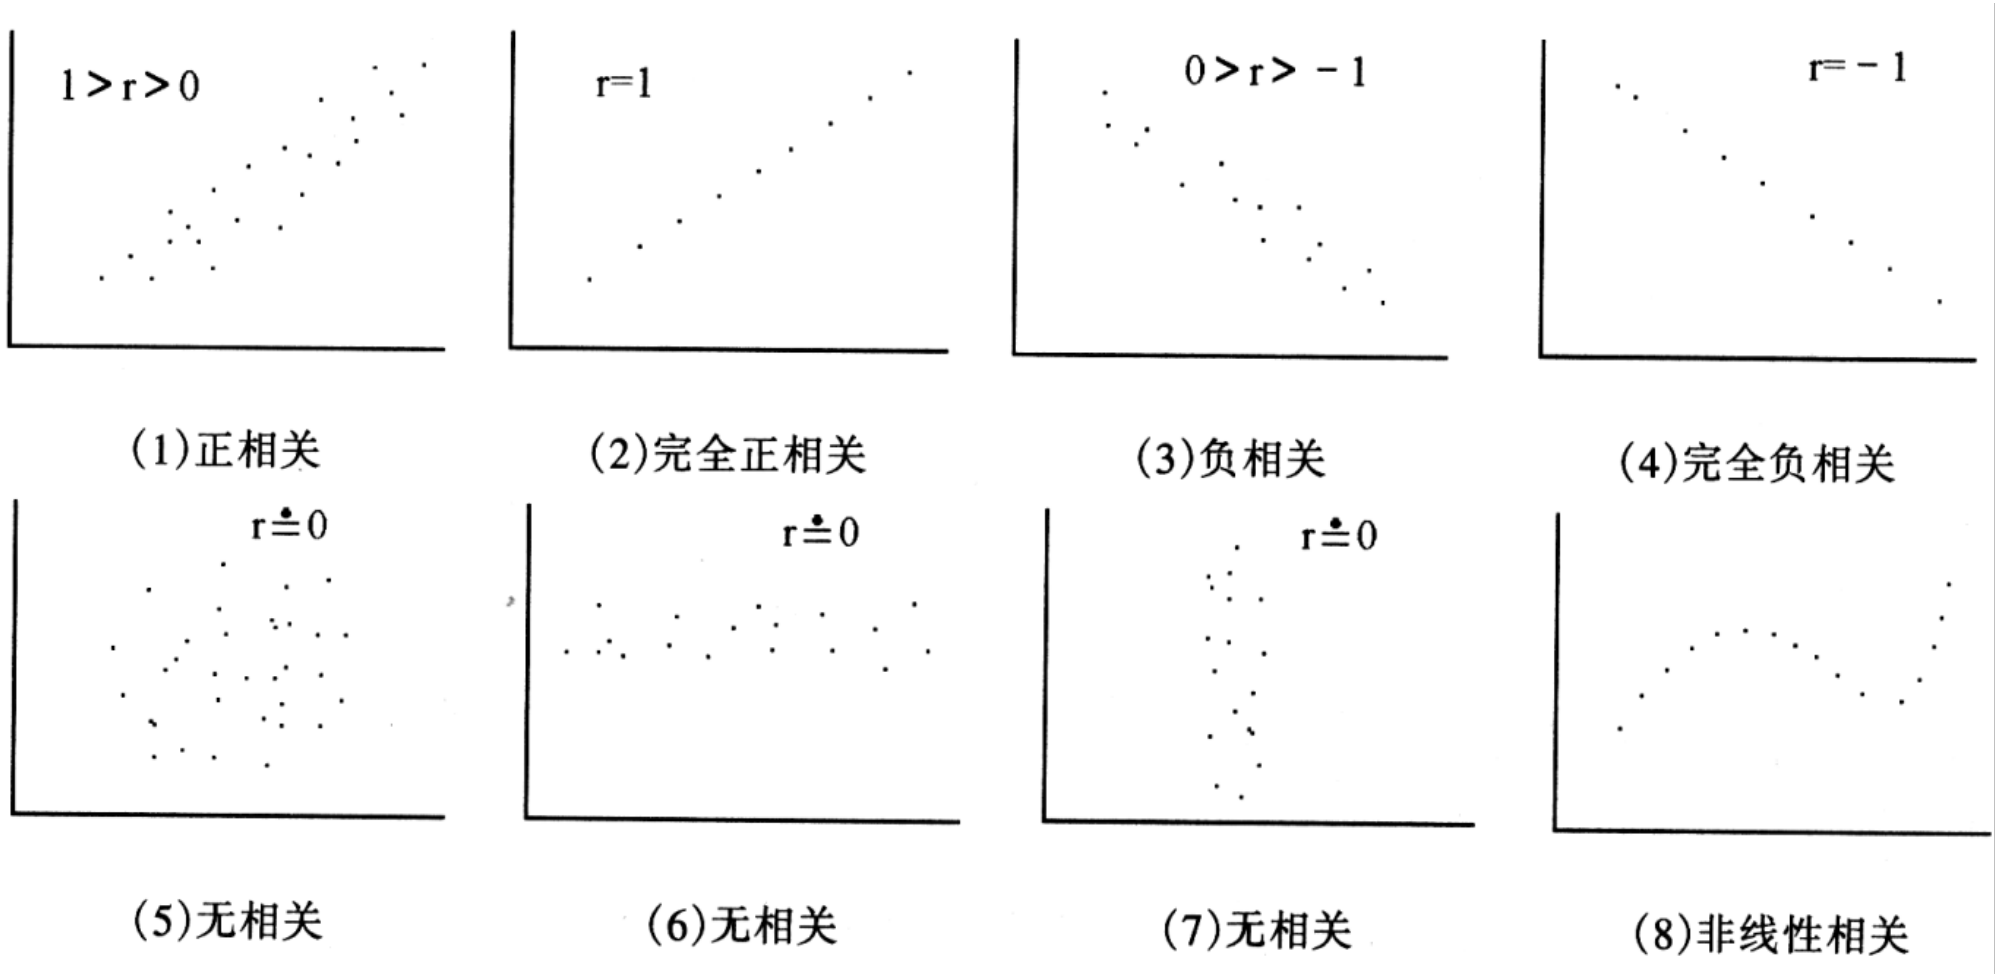


图11-2 11名男青年身高与前臂长的散点图

- **线性相关**研究随机变量之间相互联系的密切程度和方向。
- 统计学中用相关系数描述线性相关的强度和方向，记为ρ(总体相关系数)/*r*(样本相关系数)。

相关的种类：

- 线性相关用于双变量正态资料。它的性质可由散点图直观地说明。散点图中点的分布反映线性相关的性质和密切程度，可分为以下几种情况:



二、相关系数及其计算

- 在分析两个变量X与Y之间关系时，常常要了解X与Y之间有无相关关系，相关是否密切，是呈正相关还是负相关。
- 相关系数，又称Pearson积差相关系数，是说明具有直线相关关系的两个数值变量间相关**密切程度**和**相关方向**的统计量。

- 计算公式：

$$r = \frac{L_{XY}}{\sqrt{L_{XX}.L_{YY}}} = \frac{\sum (X-\bar{X})(Y-\bar{Y})}{\sqrt{\sum (X-\bar{X})^2 \sum (Y-\bar{Y})^2}}$$

相关系数的特点

- 相关系数r是一个无量纲的数值，且$-1 \le r \le 1$；
- $r > 0$为正相关，$r < 0$为负相关；
- r的绝对值越接近于1，说明相关性越强，越接近于0，说明相关性越弱。

表1 11名男青年身高与前臂长的测量结果

编号	身高（cm） (*X*)	前臂长（cm） (*Y*)
1	170	47
2	173	42
3	160	44
4	155	41
5	173	47
6	188	50
7	178	47
8	183	46
9	180	49
10	165	43
11	166	44

案例分析：

相关的统计学描述与推断：

1. 男青年的身高和前臂长有关联吗?
2. 是线性联系还是非线性关系?
3. 若二者有线性相关，相关联的程度如何?
4. 二者是正相关还是负相关?
5. 二者的线性相关有统计学意义吗?

分析步骤：

（1）绘制散点图

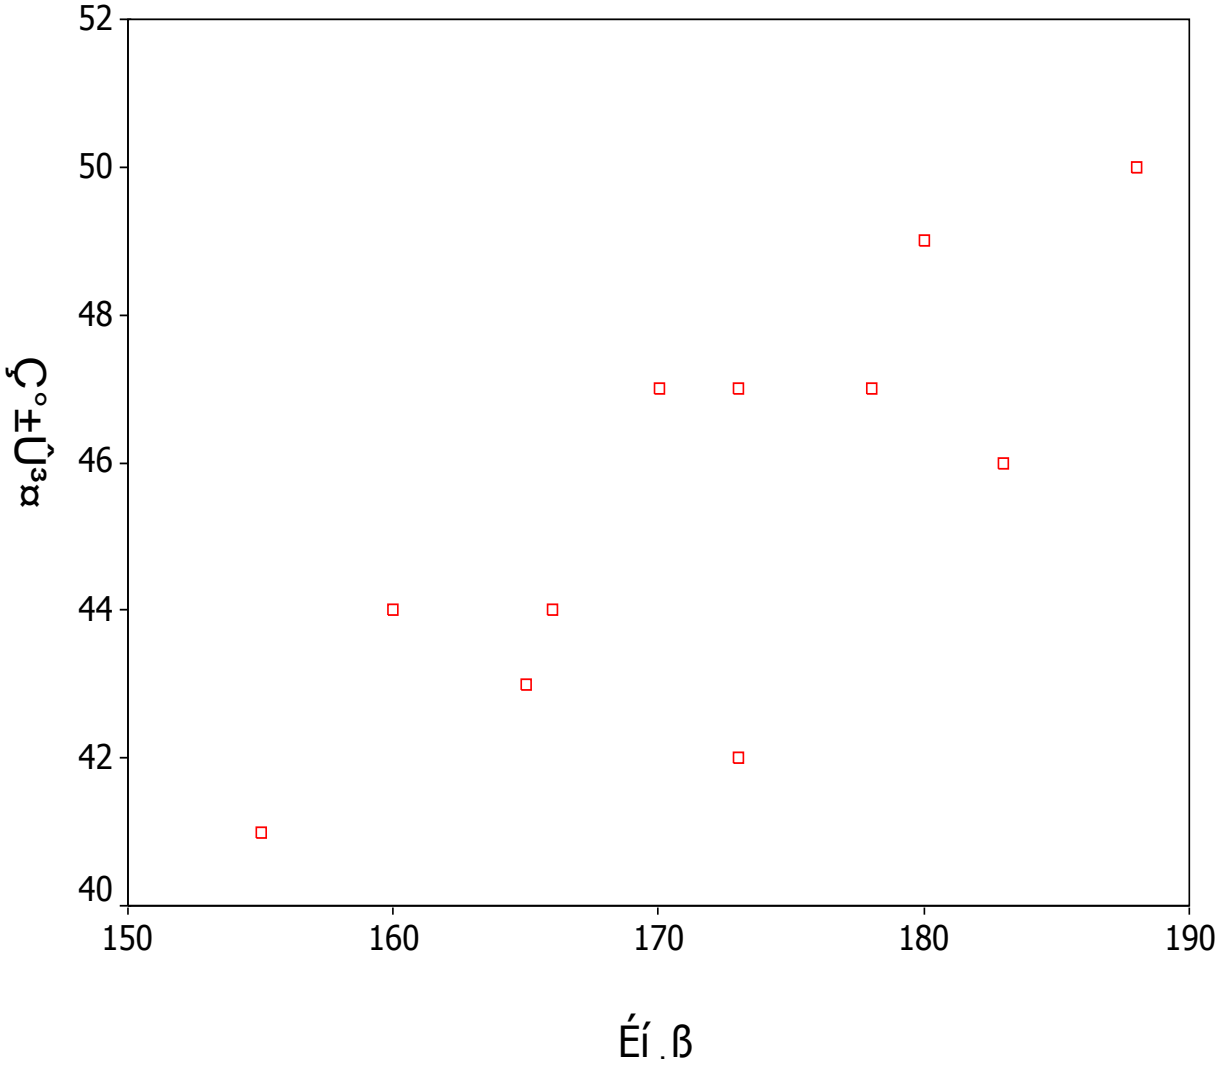


图1 11名男青年身高与前臂长的散点图

（2）计算Pearson相关系数

按公式可算得：

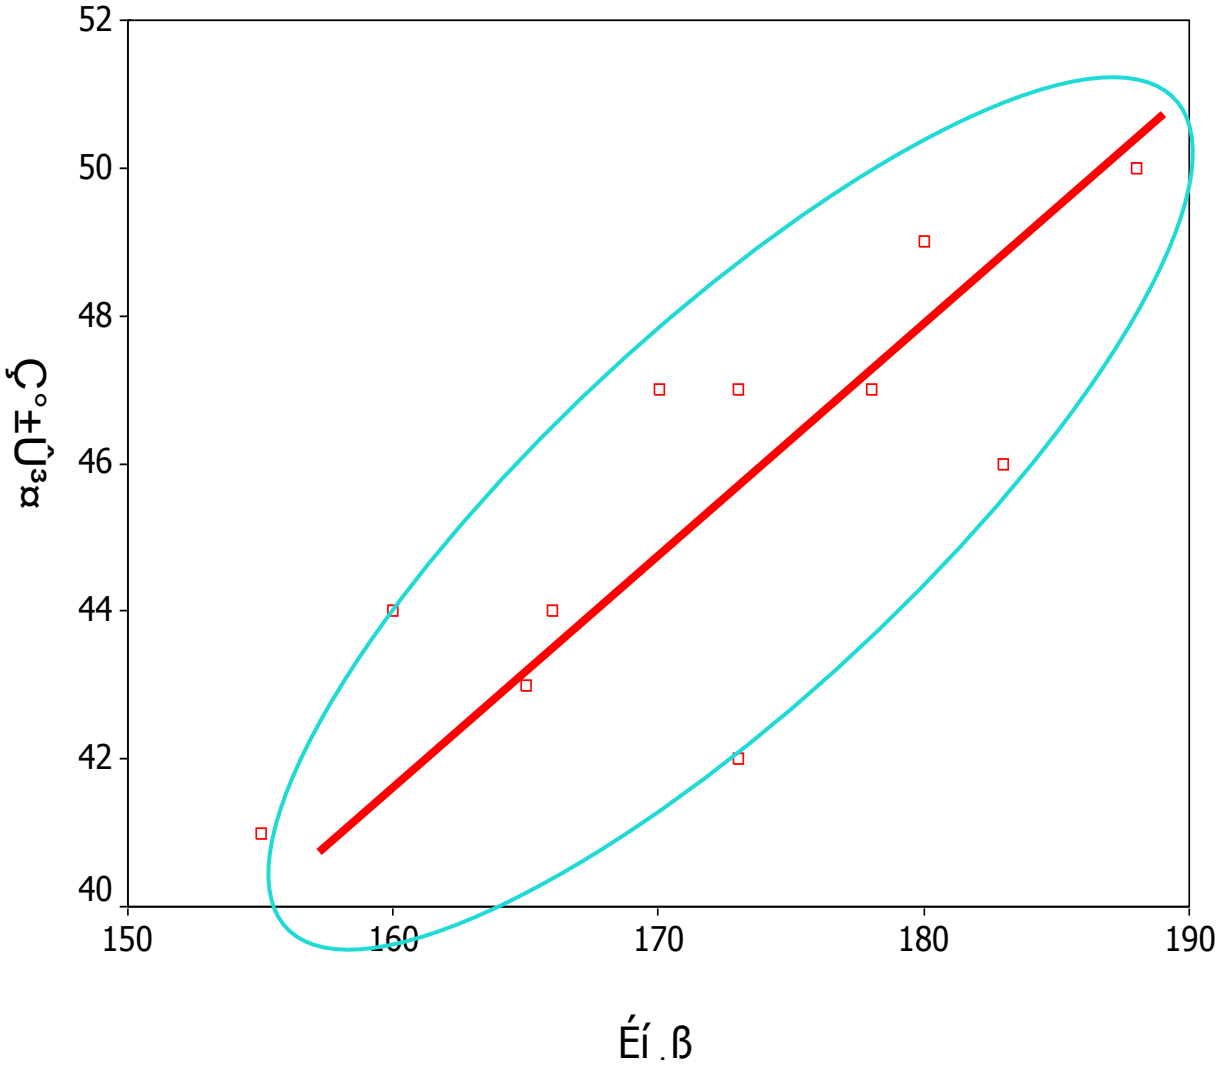
$$r = \frac{230.455}{\sqrt{1000.909 \times 82.727}} = 0.8009$$

散点图与样本相关系数均提示，11名男青年的前臂长与身高呈正相关关系，而且相关程度较高

Pearson 积矩相关系数**应用条件**：

- 随机变量；
- 呈双变量正态分布；
- 散点图呈线性趋势；
- 各观察值间相互独立。

（3）相关系数统计推断



r =0.801

$\rho \neq 0$?

相关系数的假设检验：*t* 检验

（1）确立检验假设，确定检验水准

H_0：ρ=0；　H_1：ρ≠0；　α=0.05

（2）计算检验统计量

$$t=\frac{|r-0|}{\sqrt{\frac{1-r^2}{n-2}}},\upsilon=n-2$$　　t =4.012

（3）确定*P*值，作出结论

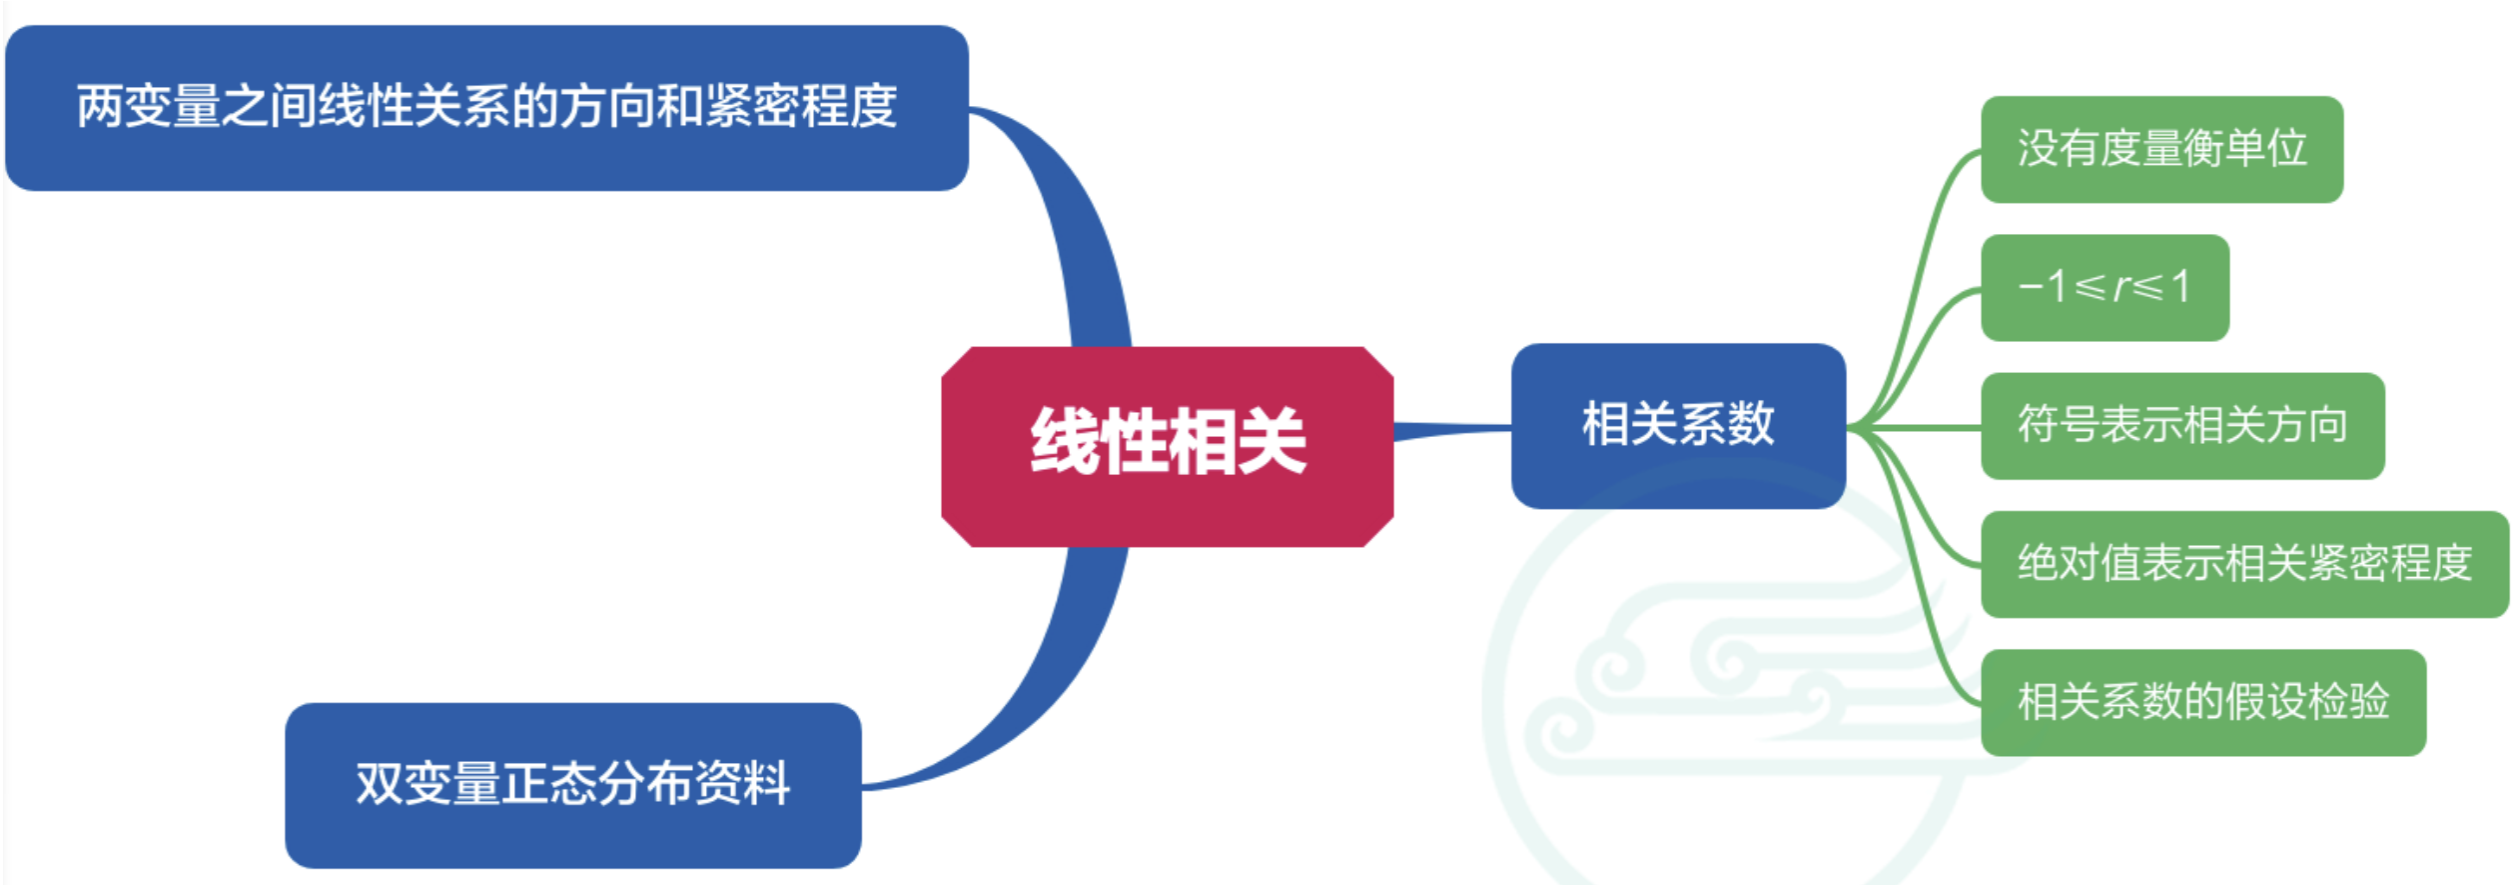
P=0.003

拒绝H_0，可以认为男青年身高与前臂长之间存在**高度正相关**关系

案例分析的结果报告：

1. 首先绘制散点图，散点图提示两变量有线性共变趋势；
2. 两变量总体满足双变量正态分布，计算Pearson相关系数，r=0.801；
3. 假设检验：t=4.012；P=0.003；
4. 可以认为总体上，男青年身高和前臂长之间呈高度正相关关系。

小结


两变量之间线性关系的方向和紧密程度
线性相关
双变量正态分布资料
相关系数
没有度量衡单位
$-1 \leqslant r \leqslant 1$
符号表示相关方向
绝对值表示相关紧密程度
相关系数的假设检验

主要内容

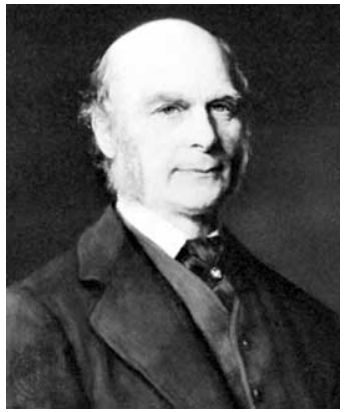
1 第一节 线性相关

2 第二节 线性回归

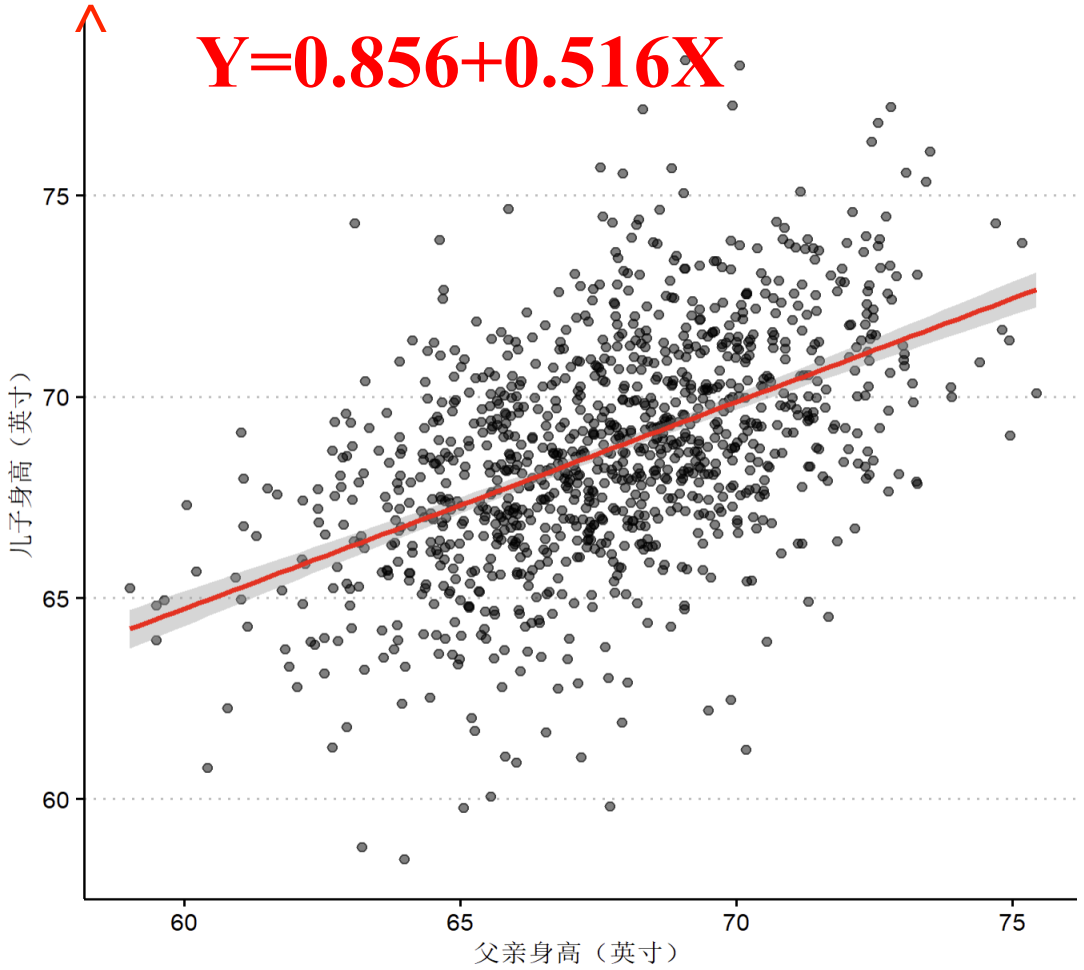
3 第三节 线性回归与相关应用的注意事项

一、线性回归的基本概念

- **线性回归**是研究随机变量之间的线性数量依存关系。



F. Galton





https://cloud.tencent.com/developer/article/1412178

线性回归方程的形式为：

$$\hat{Y} = a + bX$$

Y-hat 是反应变量*Y*的平均值

X **自变量或解释变量**

a **为截距: X为0时， Y取值的平均水平**

b **为回归系数：表示*X*每改变一个单位, *Y*的平均改变*b*个单位**

计算公式

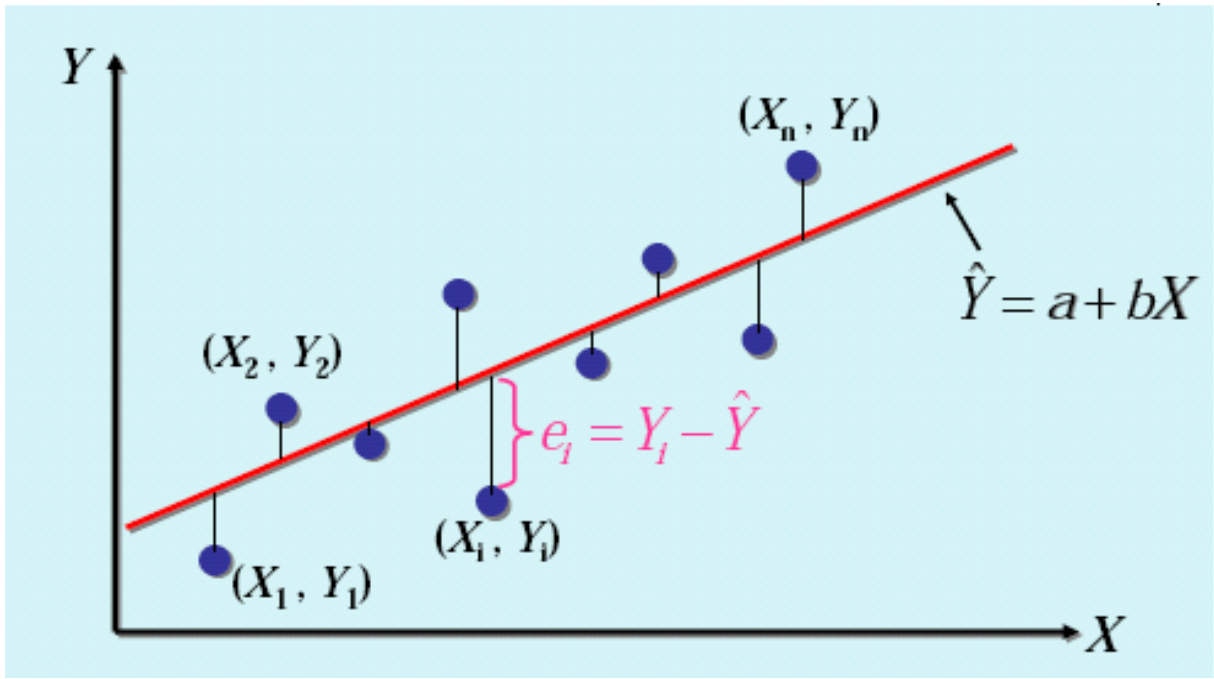
$$b = \frac{\Sigma(X - \overline{X})(Y - \overline{Y})}{\Sigma(X - \overline{X})^2} = \frac{\Sigma XY - (\Sigma X)(\Sigma Y)/n}{\Sigma X^2 - (\Sigma X)^2/n}$$

$$a = \overline{Y} - b\overline{X}$$

最小二乘估计

- 各个实测点至该直线的纵向距离（即残差）的平方和最小。
- 残差平方和越小，该直线对散点趋势的代表性越好。

$$SS_{残差} = \sum \left(Y - \hat{Y}\right)^2$$



- 回归方程中，*Y*随*X*的改变而相应地改变，称*Y*为反应变量，又称因变量；
- *X*为解释变量，又称自变量，通常我们把自变量看作影响因素。
- *X*可以是随机变量，也可以是人为选择的数值；而*Y*只能是连续型随机变量。

二、回归方程的估计

例2 研究饮用水中氟含量与成人骨X线改变指数间的关系，得到表2所示的资料，试进行回归分析。

表2 饮水氟含量（mg/L）与骨X线改变指数回归分析数据

调查对象	饮水氟含量（*X*）	骨X线改变指数（*Y*）
1	0.24	0.40
2	0.80	0.56
3	1.00	1.91
4	1.80	0.86
5	3.12	5.25
6	4.10	3.40
7	5.60	58.38
8	10.27	70.33
9	10.81	116.30

案例分析：

- 本研究目的是通过分析与骨X线改变相关的影响因素（如饮水氟含量），为控制骨X线改变相关的疾病提供依据。
- 研究一个变量的变化（如成人骨X线改变指数）受到另外一个变量（如饮水氟含量）变化的影响。这类问题在统计学中采用线性回归来进行分析。

构建线性回归方程需考虑的问题:

1. 骨X线改变指数随饮水氟含量的增加而增加吗?
2. 依存关系是直线趋势还是曲线趋势?
3. 如何采用回归方程定量地描述饮水氟含量对骨X线改变指数的影响?
4. 饮水氟含量每增加1个单位，骨X线改变指数平均会增加多少?
5. 饮水氟含量对骨X线改变的影响有统计学意义吗?

（1）绘制散点图：

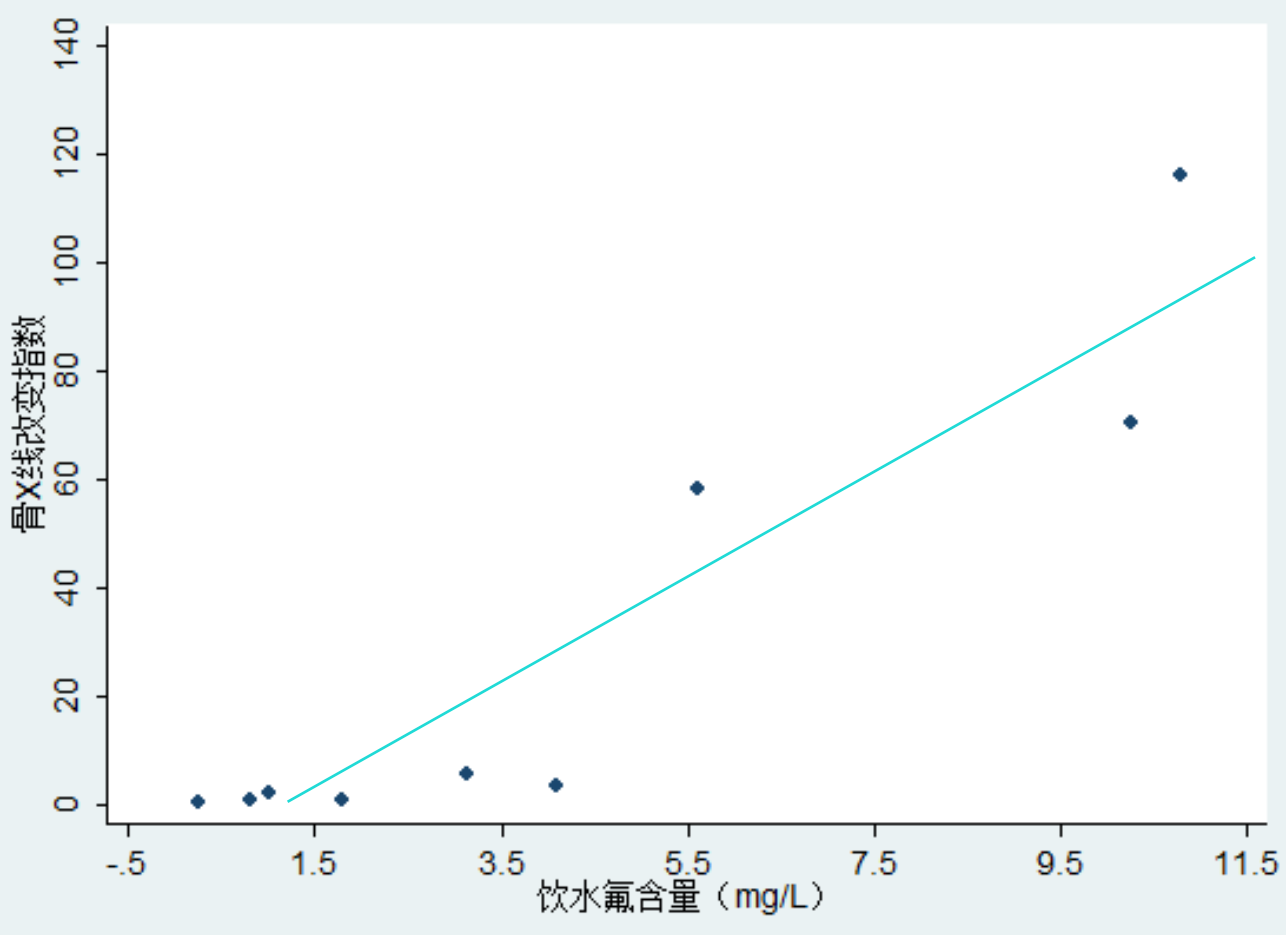


图2 饮水氟含量与成人骨X线改变指数之间关系的散点图

- 由图可知，饮水氟含量升高，成人骨X线改变指数也趋向升高；

（2）计算回归系数与常数项：

$$b=\frac{l_{XY}}{l_{XX}}=\frac{\sum XY-\frac{(\sum X)(\sum Y)}{n}}{\sum X^2-\frac{(\sum X)^2}{n}}=\frac{2340.75-\frac{37.74\times 257.39}{9}}{285.17-\frac{37.74^2}{9}}=\frac{1261.43}{126.91}=9.940$$

a=-13.049

则样本的回归方程为：$\hat{Y}=-13.049+9.94X$

回归系数的含义：

- b的统计学意义是X每增加（或减少）一个单位，Y平均改变b个单位。 b越大表示Y随X增减变化的趋势越陡。
- $b>0$，表明Y与X呈同向线性变化趋势；
- $b<0$，表明Y与X呈反向线性变化趋势；
- $b=0$，表明Y与X无线性回归关系，但并不表明没有其它关系。

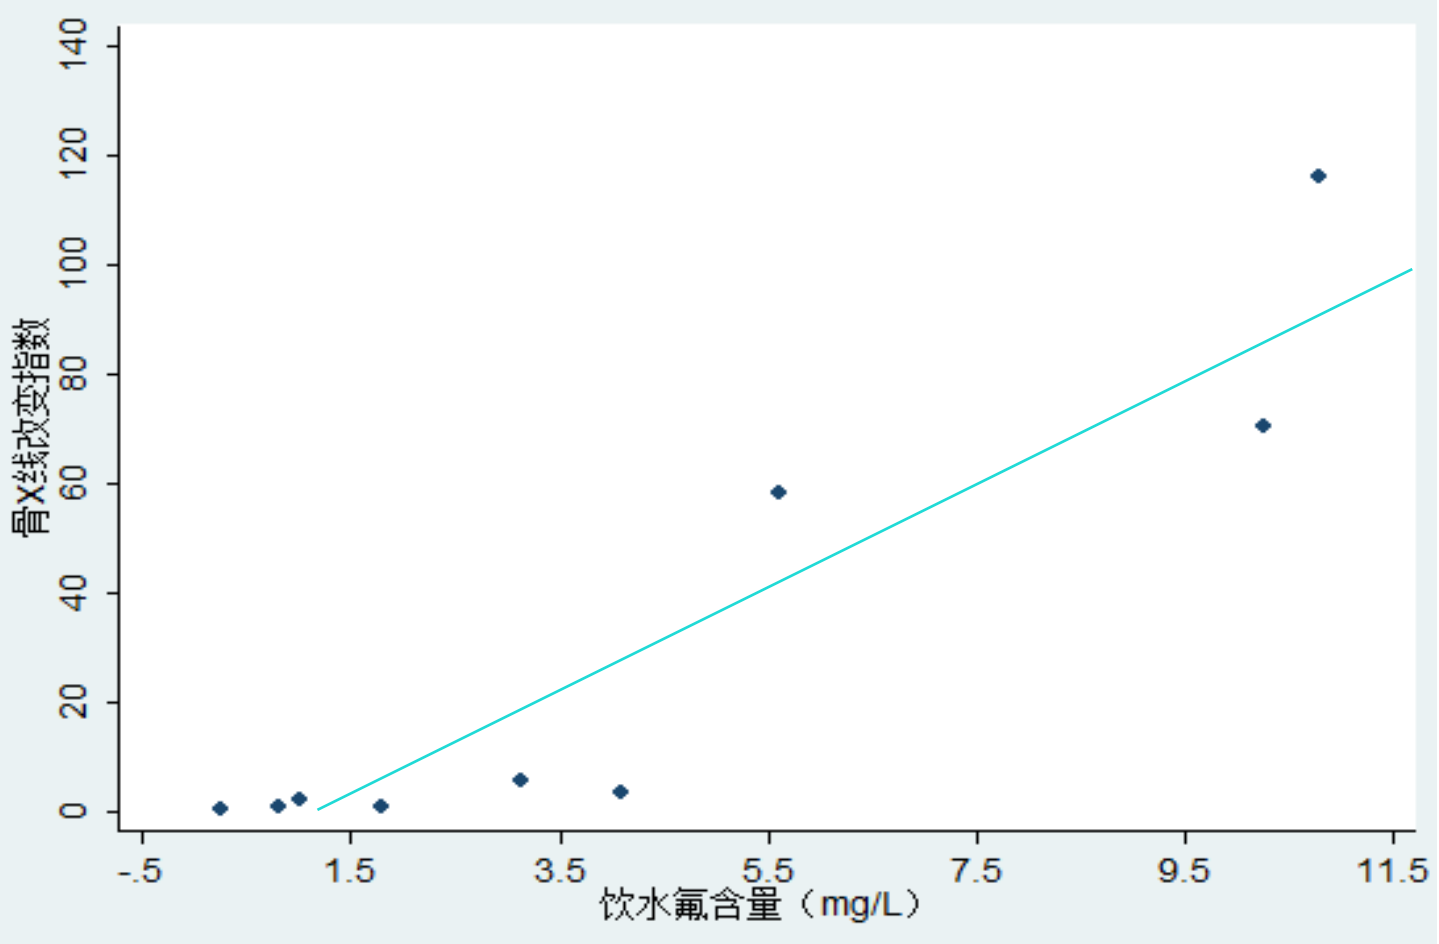
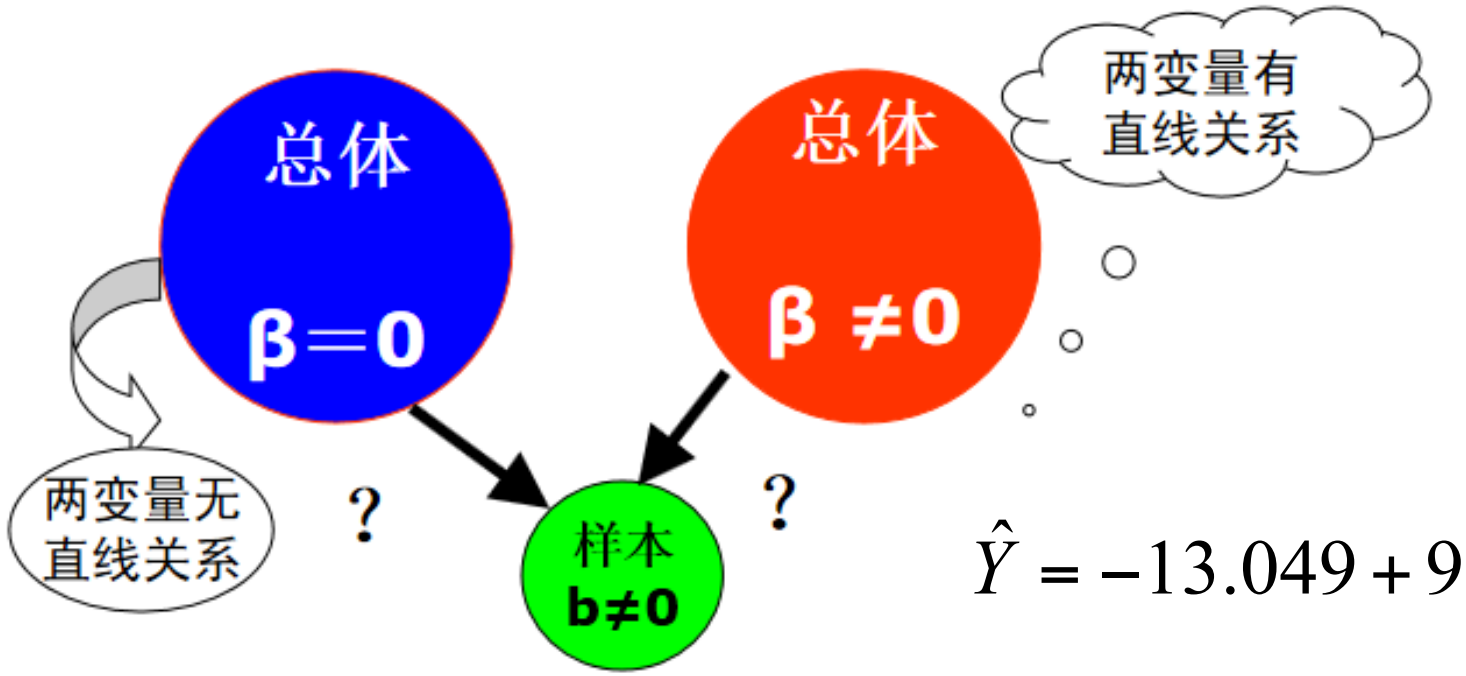


图2 饮水氟含量与成人骨X线改变指数之间的关系

- 散点呈直线趋势，但并不完全在一条直线上，说明除受自变量影响外，还有其他因素对Y起作用。

三、线性回归的假设检验



$$\hat{Y} = -13.049 + 9.94X$$

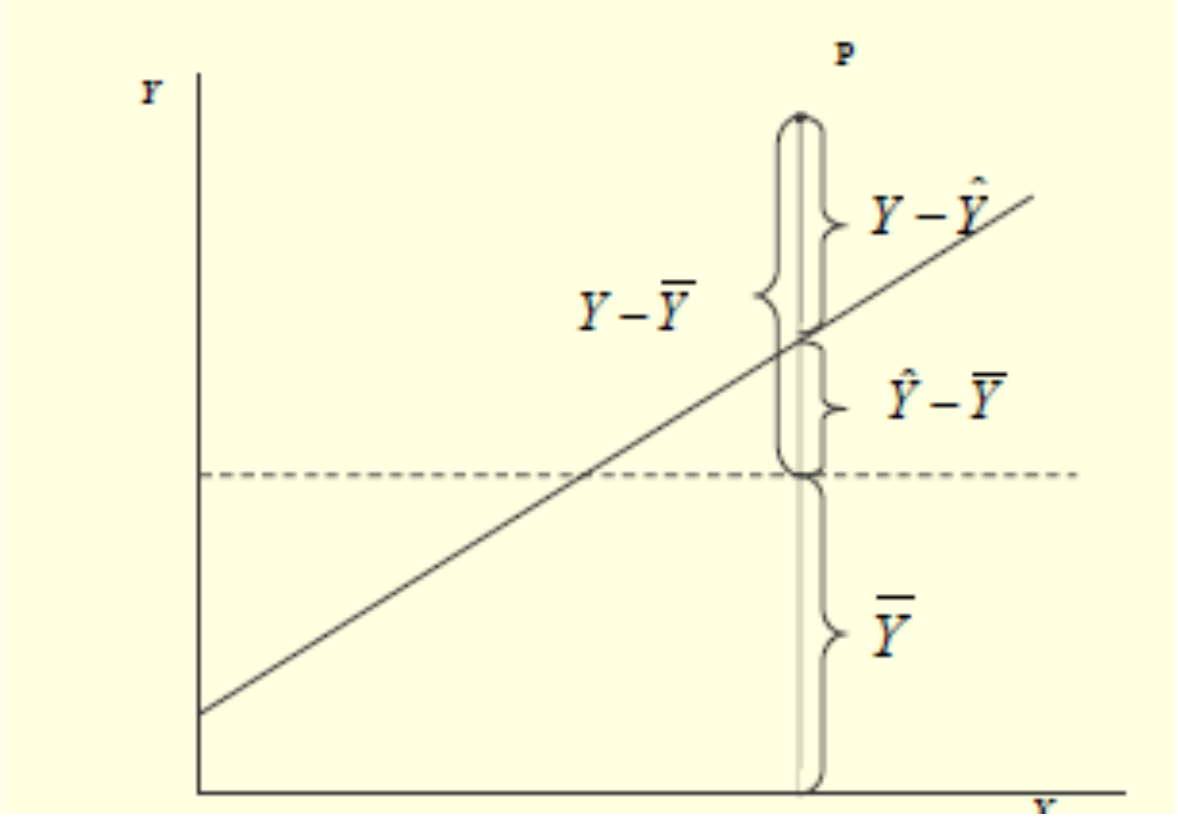
假设检验包括两个方面：

1. 回归模型是否成立：方差分析

2. 总体回归系数是否为零：*t*检验。

（一）方差分析

Y值总变异的分解：



Y的总变异分解示意图

表示Y的总变异

在Y的总变异中，可用Y与X的线性关系解释的那部分变异

除X对Y的线性影响外，其他随机因素对Y的变异的影响

$$\sum (Y-\bar{Y})^2 = \sum (\hat{Y}-\bar{Y})^2 + \sum (Y-\hat{Y})^2$$

$$SS_{总} = SS_{回归} + SS_{残差}$$

- 回归方程检验的基本思想：如果X与Y之间无线性回归关系，则$SS_{回归}$与$SS_{残差}$都只包含随机因素对Y的影响，因此两者均方应近似相等，如果差别较大，并超出随机波动可解释的范围，则认为回归方程有统计学意义。

回归模型的假设检验

（1）确立检验假设，确定检验水准

H_0：总体回归方程不成立，等价于$\beta=0$

H_1：总体回归方程成立，等价于 $\beta\neq0$

$\alpha=0.05$

（2）计算统计量

表3 方差分析表

变异来源	*SS*	*v*	*MS*	*F*	*P*
总变异	14563.13	8			
回归	12538.06	1	12538.06	43.34	＜0.001
残差	2025.07	7	289.30		

（3）确定*P*值，得出统计结论

$P<0.001$

按$\alpha=0.05$检验水准，拒绝H_0，总体回归模型成立，可以认为总体上饮水氟含量与成人骨*X*线改变指数之间存在线性回归关系。

（二）t 检验

（1）确立检验假设，确定检验水准

H_0： $\beta=0$； H_1： $\beta\neq0$； $\alpha=0.05$

（2）计算检验统计量

$$t=\frac{|b-0|}{S_b}=\frac{|9.94-0|}{1.51}=6.58$$

（3）确定*P*值，得出统计结论

$P<0.001$

拒绝H_0，结论与方差分析相同，可以看出，统计量*F*与*t*之间存在数量关系，即 $\sqrt{F}=t$ 。

结果报告

1. 散点图：提示两变量有线性共变趋势；
2. 依据样本拟合的线性回归方程：

$$\hat{Y} = -13.049 + 9.94X$$

3. 模型的假设检验：总体上回归方程成立（F=43.34，P＜0.001）；
4. 对结果的专业解释:饮用水氟含量每增加一个单位，骨X线改变指数平均增加9.94个单位（t=6.58，P＜0.001）。
5. 总体回归模型拟合效果较好，Y的总变异中，有86%的变异度可以由饮用水氟含量解释（R^2=86%）。

回归方程的应用

$$\hat{Y} = a + bX$$

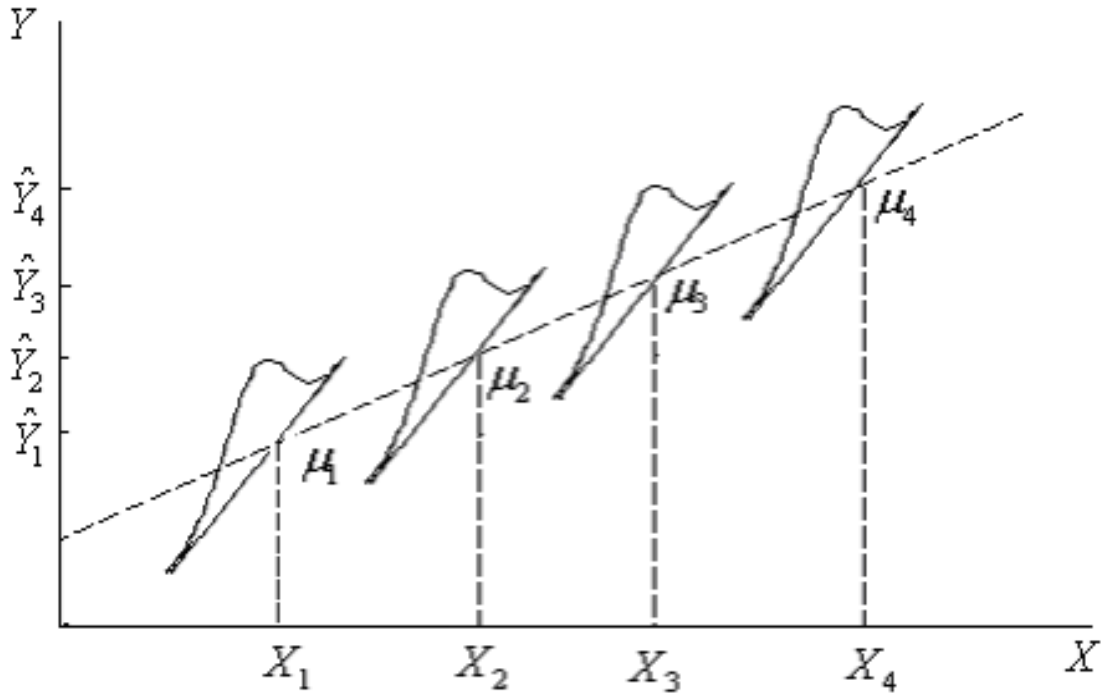
- 刻画变量间数量依存关系
- 探索危险因素（因果）
- **预测**
- 逆控制

直线回归模型的应用条件

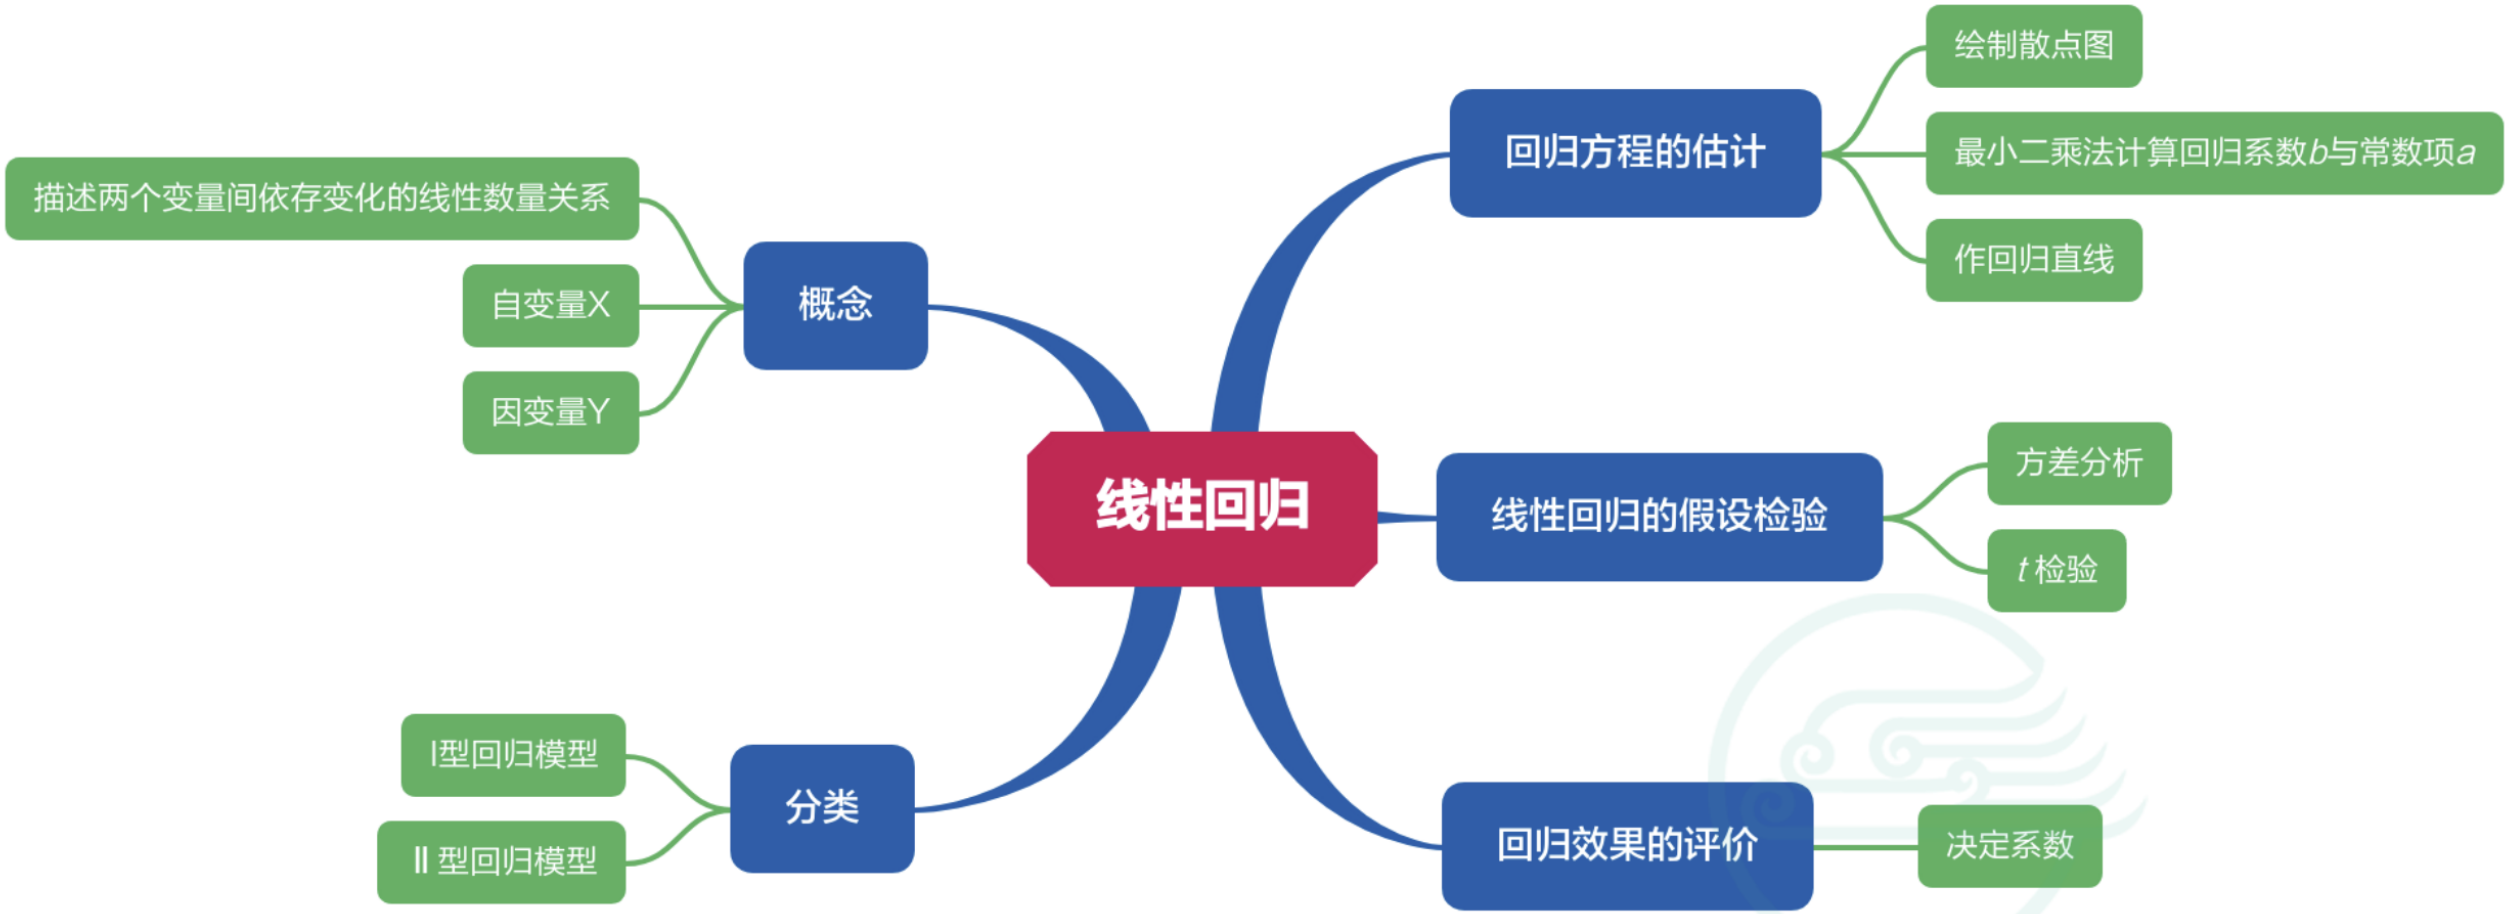
- 线性回归模型的前提

  条件是(**LINE**)：

- 线性 (**Linear**) ;
- 独立 (**Independent**) ;
- 正态 (**Normal**) ;
- 等方差 (**Equal variance**) 。



小结：


线性回归
概念
描述两个变量间依存变化的线性数量关系
自变量X
因变量Y
分类
I型回归模型
II 型回归模型
回归方程的估计
绘制散点图
最小二乘法计算回归系数b与常数项a
作回归直线
线性回归的假设检验
方差分析
t 检验
回归效果的评价
决定系数

主要内容

1 第一节 线性相关

2 第二节 线性回归

3 第三节 线性回归与相关应用的注意事项

1. 线性回归与相关的联系

- 同一组资料，r与b正负号一致。
- 同一样本，$t_r = t_b$ 。
- 回归与相关可以互相解释。

$$R^2 = r^2 = \frac{l_{XY}^2}{l_{XX}.l_{YY}} = \frac{l_{XY}^2 / l_{XX}}{l_{YY}} = \frac{SS_{回}}{SS_{总}}$$

2.1. 线性相关分析的应用

- 要求两变量均服从正态分布。
- 相关系数的实际意义需具体问题具体分析，一般认为：

  $r \leq 0.3$：相关性较差；

  $0.3 < r \leq 0.6$：中度相关；

  $0.6 < r \leq 0.8$：较高度的相关性；

  $r > 0.8$：很高的相关性；
- 相关描述两变量间联系的密切程度和方向，不能由相关推断两者有因果关系。

2.2 回归分析的应用

- 应用于：（1）分析两个变量间是否存在线性依存关系；

  （2）利用X估计Y；（3）利用回归方程进行控制。

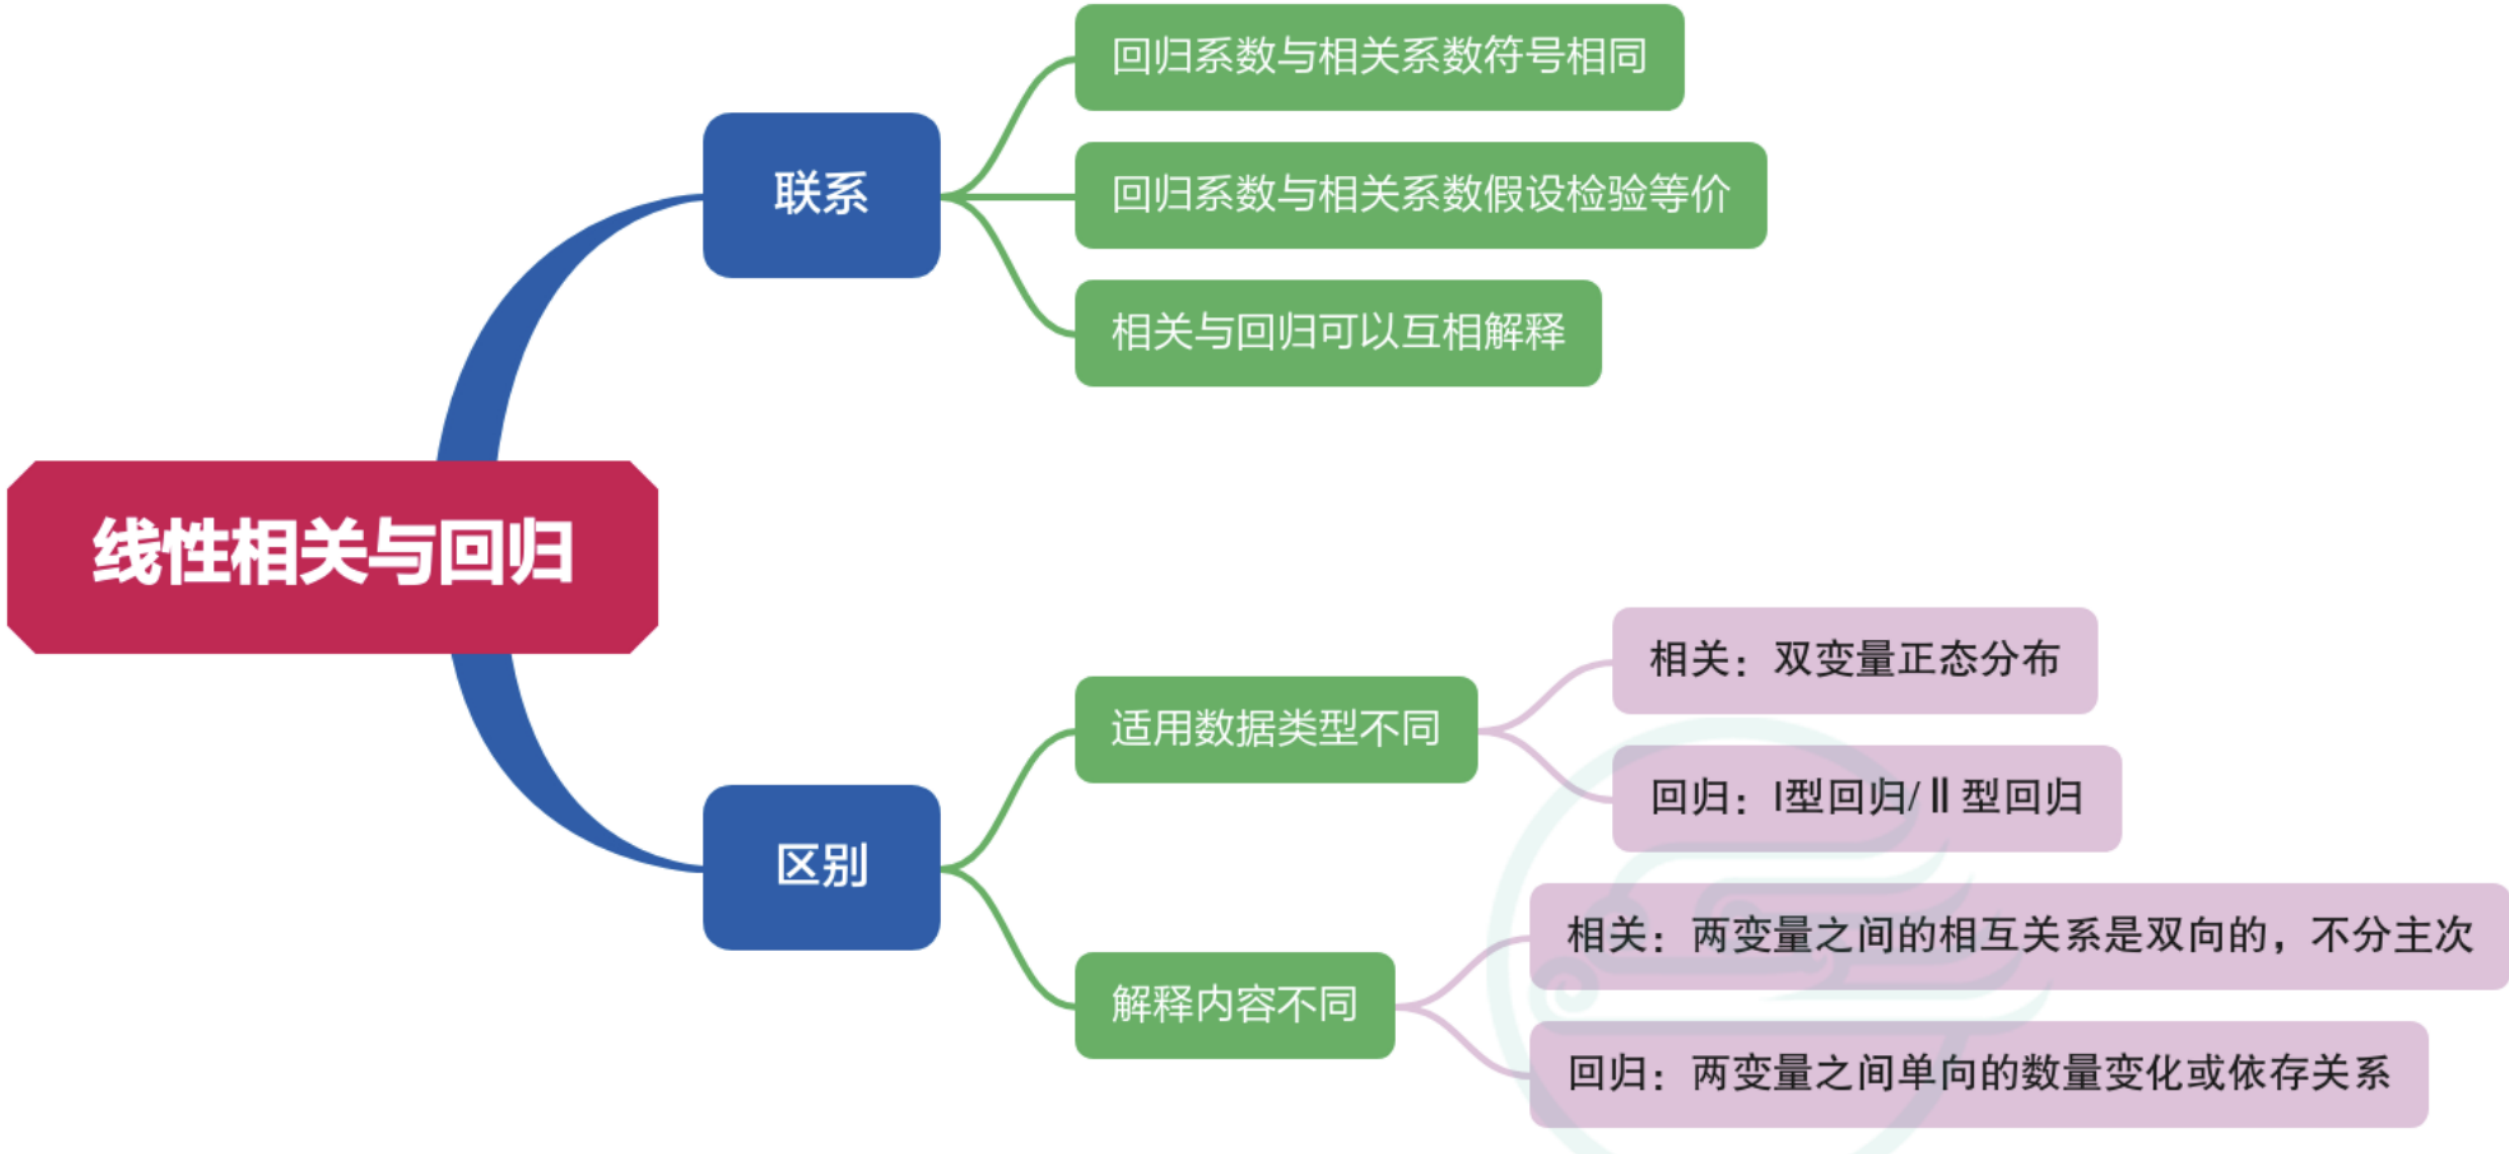
- 作回归分析时，若因果关系难以确定，应以易于测定或变异较小者为X。

- 回归分析中，X可以是随机变量（称为II型回归），也可以是给定的量（称为I型回归）。

- 使用回归方程估计Y时，自变量应在取值范围内。

3. 线性回归与相关的区别

- 相关要求X与Y为随机变量，且X和Y服从双变量正态分布。
- 回归要求Y为随机变量，服从正态分布；X可人为取值，此时称I型回归。若X与Y为随机变量，称II型回归。
- 线性相关表示两个变量之间的相关关系是双向的；线性回归则反映两个变量的关系是单向的，更适合分析因果关系的数量变化。


线性相关与回归
联系
回归系数与相关系数符号相同
回归系数与相关系数假设检验等价
相关与回归可以互相解释
区别
适用数据类型不同
相关：双变量正态分布
回归：I型回归/Ⅱ型回归
解释内容不同
相关：两变量之间的相互关系是双向的，不分主次
回归：两变量之间单向的数量变化或依存关系

The end!

Thank you!